

# Análise de Risco

## Sessão 2

### Conceitos de probabilidade

Prof. E.A. Schmitz

PPGI/UFRJ

June 18, 2018

# Espaço amostral

*Conjunto* de pontos que representa os possíveis resultados de um experimento




Figure: EA para lançamento de um dado



# Eventos

Evento: Conjunto de pontos do espaço amostral

Definição: A probabilidade de ocorrência de um evento  $A$  é a soma das probabilidades dos pontos do EA associados com o evento.

$$P\{A\} = \sum_{i=1}^n p_i$$

# Teorema da soma

Sejam  $A_1$  e  $A_2$  dois eventos de EA:

$P\{A_1 A_2\}$ : probabilidade da ocorrência conjunta de  $A_1$  e  $A_2$

$P\{A_1 + A_2\}$ : probabilidade da ocorrência de ao menos um dentre  $A_1$  e  $A_2$

Teorema da soma:

$$P\{A_1 + A_2\} = P\{A_1\} + P\{A_2\} - P\{A_1 A_2\}$$

Se:  $A_1 \cap A_2 = \emptyset$

$$P\{A_1 + A_2\} = P\{A_1\} + P\{A_2\}$$

# Teorema da multiplicação

Queremos achar:

$P\{A_1A_2\}$ : probabilidade da ocorrência conjunta de  $A_1$  e  $A_2$

$P\{A_2|A_1\}$  : probabilidade que  $A_2$  ocorra sabendo que  $A_1$  ocorreu

Então:

- ▶  $P\{A_2|A_1\} = \frac{P\{A_1A_2\}}{P\{A_1\}}$
- ▶  $P\{(A_1A_2) = P\{A_1\} \cdot P\{A_2|A_1\}$

Se:  $P\{A_2|A_1\} = P\{A_2\}$

- ▶ os eventos são independentes
- ▶  $P\{A_1A_2\} = P\{A_1\} \cdot P\{A_2\}$

# Fórmula de Bayes

Sejam  $A_1, A_2, A_n$  conjunto de eventos mutuamente exclusivos que particionam EA

Seja  $B$  evento onde  $P(B) \geq 0$

Então:  $P(A_i|B) = \frac{P(A_i) * P(B|A_i)}{P(B)}$

mas

$P(B) = P(A_1) * P(B|A_1) + P(A_2) * P(B|A_2), \dots P(A_n) * P(B|A_n)$

$$P(A_i|B) = \frac{P(A_i) * P(B|A_i)}{P(A_1) * P(B|A_1) + P(A_2) * P(B|A_2), \dots P(A_n) * P(B|A_n)}$$

# Variáveis aleatórias

Variável Aleatória(VA): é uma variável numérica definida no espaço amostral

$$VA : EA \rightarrow \mathbb{R}$$

Função de probabilidade: retorna a probabilidade que uma VA  $X$  assumo o valor  $x$ , denotado por  $f(x)$

$$f(x) = Prob(X = x)$$

Função de probabilidade cumulativa: retorna a probabilidade que  $X$  assumo o valor  $\leq x$

$$F(x) = Prob(X \leq x)$$



## Exemplo - lançamento de um dado

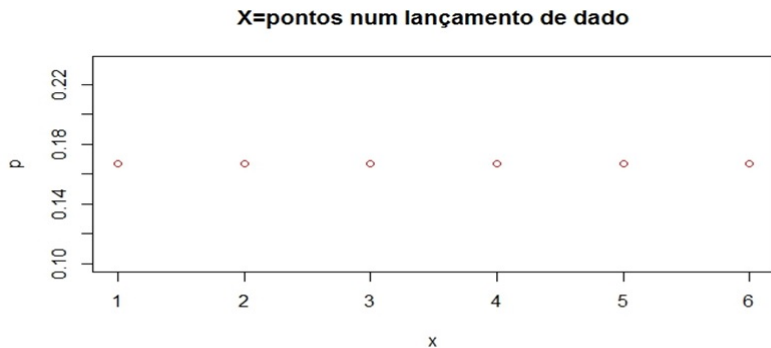


Figure: Função de probabilidade para lançamento de um dado

## Exemplo - lançamento de um dado

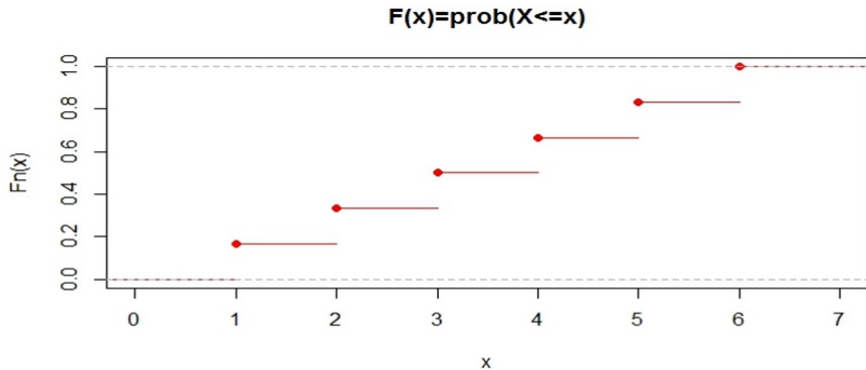


Figure: Função cumulativa para lançamento de dado

# Média

Média de uma VA com  $f_p=f(x)$ :

- ▶  $\mu = \sum_{i=1}^n x_i * f(x_i)$

- ▶  $\mu = \int_{-\infty}^{\infty} x_i * f(x_i)$

- ▶ Média representa o centro de massa do gráfico da função

# Variância

Variância de uma VA com  $f_p=f(x)$ :

- ▶  $\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2 * f(x_i)$
- ▶  $\sigma^2 = \int_{-\infty}^{\infty} (x_i - \mu)^2 * f(x_i)$
- ▶ Variância representa o espalhamento ao redor do centro de massa do gráfico da função

## Exemplo moeda

Seja  $X$ ="valor obtido ao jogar uma moeda"

- ▶  $\{H, T\} \rightarrow \{0, 1\}$
- ▶  $f(x) = \{(0, 1/2), (1, 1/2)\}$
- ▶  $\mu = 0 * f(0) + 1 + 1 * f(1) = 1/2$
- ▶  $\sigma^2 = (0 - 1/2)^2 * f(0) + (1 - 1/2)^2 * f(1) = 1/4$

# Algumas fps usadas em AR

- ▶ Uniforme: valores contínuos dentro de um intervalo
- ▶ Discreta: conjunto de valores discretos
- ▶ Triangular: continua (mínimo, mais provável e máximo)
- ▶ Normal: curva do sino (média, desvio padrão)
- ▶ Binomial: sorteio de eventos com probabilidade  $p$

# Uniforme

- ▶ VA assume valores numa faixa, todos igualmente prováveis
- ▶ R: `runif(n, min = 0, max = 1)`
- ▶ `Uniforme(0,1)`: base da geração das outras distribuições
  - ▶  $\mu = \int_0^1 x * 1dx = 1/2$
  - ▶  $\sigma^2 = \int_0^1 (x - 1/2)^2 * 1dx = 1/12$

# Triangular

- ▶ VA segue uma estimativa de 3 pontos: mínimo ( $a$ ) , mais provável ( $m$ ) e máximo ( $b$ )
- ▶ R: `rtriangle(min,max, mprov)` Package:triangle
- ▶  $\mu = (a + b + m)/3$
- ▶  $\sigma^2 = (a^2 + b^2 + m^2 - a * b - a * m - b * m)/18$



# Normal 1

- ▶ VA expressa variabilidade de muitos fenomenos naturais
- ▶ R: `rnorm(mu,sd)`
- ▶  $f(x) = \frac{1}{2*\pi} * e^{-\frac{(x-\mu)^2/\sigma^2}{2}}$
- ▶ média= $\mu$
- ▶ variancia= $\sigma^2$

## Normal 2

Normal reduzida:  $\mu = 0, \sigma^2 = 1$

Alguns números importantes:

- ▶  $Prob(-1 \leq X \leq 1) = 0.68$
- ▶  $Prob(-2 \leq X \leq 2) = 0.95$
- ▶  $Prob(-2.3 \leq X \leq 2.3) = 0.98$
- ▶  $Prob(-3 \leq X \leq 3) = 0.995$

# Teoremas 1

Teorema 1: Transformação linear de VAs

Sejam  $\mu, \sigma^2$  os parâmetros de  $X$ :

Se  $X_1 = a * X + b$  então seus parâmetros são:

$$\mu_1 = a * \mu + b$$

$$\sigma_1^2 = a^2 * \sigma$$

## Teoremas 2

Teorema 2: Soma de n VAs

Seja

$$Z = \sum_{i=1}^n X_i$$

Se os parâmetros de  $X_i = (\mu_i, \sigma_i^2)$  então os parâmetros de  $Z$  são:

$$\mu_z = \sum_{i=1}^n \mu_i$$

$$\sigma_z^2 = \sum_{i=1}^n \sigma_i^2$$

## Teoremas 3

Teorema 3: Uso da normal reduzida

Sejam  $X \sim Normal(\mu, \sigma^2)$  e  $\Phi \sim Normal(0, 1)$

$$P(a < X \leq b) = F(b) - F(a) = \Phi((b - \mu)/\sigma) - \Phi((a - \mu)/\sigma)$$

## Teoremas 4

Teorema 4: Soma de  $n$  VAs normais independentemente distribuidas

Sejam  $X_i \sim \text{Normal}(\mu_i, \sigma_i^2), i \in 1..n$

$$Z = \sum_1^n X_i$$

então:

- ▶  $Z \sim \text{Normal}(\mu_z, \sigma_z^2)$
- ▶  $\mu_z = \sum_1^n \mu_i$
- ▶  $\sigma_z = \sum_1^n \sigma_i^2$

## Teoremas 5

Teorema 5: Teorema central do limite (TCL)

Sejam  $X_i, i \in 1..n$ , independentemente distribuidas com  $(\mu_i, \sigma_i^2)$

$$Z = \sum_1^n X_i$$

então se  $n \rightarrow \infty$

- ▶  $Z \rightarrow Normal(\mu_z, \sigma_z^2)$
- ▶  $\mu_z = \sum_1^n \mu_i$
- ▶  $\sigma_z = \sum_1^n \sigma_i^2$

# Monte Carlo

- ▶ Conseguir soluções aproximadas para funções complexas através de amostragem computacional.
- ▶ Exemplo: algoritmo para calcular valor de  $\pi$  por amostragem:
  - ▶ Lançar  $N$  dardos ao acaso dentro do quadrado de lado  $= 2$
  - ▶ Contar o número de acertos  $A$  dentro do círculo inscrito
  - ▶  $\pi \sim 4 * (A/N)$