



COPPE/UFRJ

# NC-WISARD: UMA INTERPRETAÇÃO SEM PESOS DO MODELO NEURAL NEOCOGNITRON

Lawrence Cruvinel Bandeira

Dissertação de Mestrado apresentada ao Programa de Pós-graduação em Engenharia de Sistemas e Computação, COPPE, da Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Mestre em Engenharia de Sistemas e Computação.

Orientador: Felipe Maia Galvão França

Rio de Janeiro

Setembro de 2010

NC-WISARD: UMA INTERPRETAÇÃO SEM PESOS DO MODELO NEURAL  
NEOCOGNITRON

Lawrence Cruvinel Bandeira

DISSERTAÇÃO SUBMETIDA AO CORPO DOCENTE DO INSTITUTO  
ALBERTO LUIZ COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA DE  
ENGENHARIA (COPPE) DA UNIVERSIDADE FEDERAL DO RIO DE  
JANEIRO COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A  
OBTENÇÃO DO GRAU DE MESTRE EM CIÊNCIAS EM ENGENHARIA DE  
SISTEMAS E COMPUTAÇÃO.

Examinada por:

---

Prof. Felipe Maia Galvão França, Ph.D.

---

Prof. Ricardo Farias, D.Sc.

---

Prof. Wilson Rosa de Oliveira Junior, D.Sc.

RIO DE JANEIRO, RJ – BRASIL

SETEMBRO DE 2010

Bandeira, Lawrence Cruvinel

NC-WiSARD: Uma Interpretação sem Pesos do Modelo Neural Neocognitron/Lawrence Cruvinel Bandeira. – Rio de Janeiro: UFRJ/COPPE, 2010.

XII, 49 p.: il.; 29 7cm.

Orientador: Felipe Maia Galvão França

Dissertação (mestrado) – UFRJ/COPPE/Programa de Engenharia de Sistemas e Computação, 2010.

Referências Bibliográficas: p. 47 – 49.

1. Redes Neurais. 2. Reconhecimento de imagens. 3. Arquitetura multicamadas. I. França, Felipe Maia Galvão. II. Universidade Federal do Rio de Janeiro, COPPE, Programa de Engenharia de Sistemas e Computação. III. Título.

*Concentre-se naquilo que você é  
bom, delegue todo o resto.*

*Steve Jobs*

# Agradecimentos

Ao Programa de Engenharia de Sistemas e Computação (PESC/COPPE/UFRJ) por fornecer a oportunidade e suporte para o desenvolvimento e conclusão deste trabalho de Mestrado.

Ao meu orientador Felipe França, pelo acompanhamento e ajuda fornecidas ao percorrer todos os estágios durante esses três anos e meio de pesquisa. Obrigado além de tudo, por propiciar um clima agradável no ambiente de trabalho, e amizade fora dele.

À minha mãe e irmã por apoiarem de forma incondicional em todas as etapas da minha vida, sendo esta uma das mais importantes.

À minha nova família que trouxe inigualável felicidade em minha vida pessoal com o nascimento do meu filho Gabriel. Obrigado a Mariana, minha companheira de todas as horas, por me apoiar todo o tempo.

Aos amigos que ingressaram no PESC e percorreram o mesmo caminho, auxiliando sempre que preciso. Obrigado pela amizade e por propiciar momentos de descontração, importantes para o contínuo trabalho. Menção especial aos amigos Leandro Marzulo e Bruno França que me ajudaram a superar obstáculos importantes relativos ao trabalho desenvolvido.

E obrigado à DEUS pelas inúmeras oportunidades dadas, e sabedoria em saber aproveitá-las. Obrigado por tudo.

Resumo da Dissertação apresentada à COPPE/UFRJ como parte dos requisitos necessários para a obtenção do grau de Mestre em Ciências (M.Sc.)

## NC-WISARD: UMA INTERPRETAÇÃO SEM PESOS DO MODELO NEURAL NEOCOGNITRON

Lawrence Cruvinel Bandeira

Setembro/2010

Orientador: Felipe Maia Galvão França

Programa: Engenharia de Sistemas e Computação

Entre as áreas de estudo da inteligência artificial, destaca-se o reconhecimento de imagens através de redes neurais artificiais. Baseadas em modelos matemáticos de neurônios, redes neurais como o Neocognitron, foram precursoras no reconhecimento de padrões de imagens. Buscando desempenho computacional, surgiram os modelos computacionais de neurônios, que formariam as redes neurais sem peso. A WiSARD foi uma das primeiras redes neurais sem peso, e através de seus neurônios baseados em memórias de acesso aleatório, trouxe desempenho ao processo de reconhecimento de imagens. A NC-WiSARD é uma rede neural baseada na rede hierárquica multicamadas do Neocognitron, no perceptron sem-peso WiSARD e também em sua variação que utiliza o método de treinamento não-supervisionado, a AUTO-WiSARD. É através da hierarquia multicamadas que é possível o reconhecimento correto não só de padrões que foram treinados, mas de qualquer variação que ocorra em tamanho, posicionamento além de imperfeições que podem acompanhar a imagem. Com habilidade de extração de padrões simples e relevantes das imagens, a NC-WiSARD consegue, de maneira equivalente ao Neocognitron, reconhecer e compor padrões mais complexos através de sua estrutura hierárquica.

Abstract of Dissertation presented to COPPE/UFRJ as a partial fulfillment of the requirements for the degree of Master of Science (M.Sc.)

## NC-WISARD: A WEIGHTLESS INTERPRETATION OF THE NEOCOGNITRON NEURAL MODEL

Lawrence Cruvinel Bandeira

September/2010

Advisor: Felipe Maia Galvão França

Department: Systems Engineering and Computer Science

Among the research areas of artificial intelligence, there is image recognition through neural networks. Based on mathematical models of neurons, neural networks as Neocognitron, were precursors to the image recognition. Seeking performance computing, computational models of neurons have emerged, which would become the weightless neural networks. The WiSARD was one of the first weightless neural networks, and through your neurons based on random-access memories, brought pattern recognition performance. The NC-WISARD is a neural network based on the Neocognitron's multilayered hierarchical network, on the the weightless WiSARD perceptron and also on its variation with non-supervised training methodology, the AUTO-WiSARD. The multilayered hierarchy enables the correct recognition, not only of previously trained patterns, but also any variation of size, position and distortions that the image may have. With the hability of extraction of patterns that are simple and relevant to the images, the NC-WiSARD can, like Neocognitron, through its hierarchical structure, recognize and assemble more complex patterns.

# Sumário

<b>Lista de Figuras</b>	<b>x</b>
<b>Lista de Tabelas</b>	<b>xii</b>
<b>1 Introdução</b>	<b>1</b>
1.1 Motivação . . . . .	2
1.2 Objetivo . . . . .	3
1.3 Contribuições . . . . .	3
1.4 Metodologia . . . . .	4
1.5 Organização da dissertação . . . . .	4
<b>2 Modelos Neurais</b>	<b>5</b>
2.1 Redes Neurais Sem Peso . . . . .	6
2.1.1 WiSARD . . . . .	7
2.1.2 AUTO-WiSARD . . . . .	13
2.2 Neocognitron . . . . .	16
<b>3 NC-WiSARD</b>	<b>19</b>
3.1 Arquitetura proposta . . . . .	19
3.2 Treinamento . . . . .	23



3.3	Reconhecimento . . . . .	30
3.4	Configurações . . . . .	31
3.5	Decisões de projeto . . . . .	34
<b>4</b>	<b>Experimentos</b>	<b>38</b>
4.1	Visualizando a NC-WiSARD . . . . .	39
4.2	Resultados . . . . .	42
<b>5</b>	<b>Conclusões e Trabalhos Futuros</b>	<b>45</b>
	<b>Referências Bibliográficas</b>	<b>47</b>

# Lista de Figuras

2.1	Neurônio Artificial de McCulloch e Pitts [24] . . . . .	6
2.2	RAM neurônio $i$ com $n$ entradas . . . . .	7
2.3	Discriminador . . . . .	8
2.4	Treinamento de um discriminador [6] . . . . .	9
2.5	A <i>WiSARD</i> . . . . .	10
2.6	Aprendizado de um discriminador em formato binário e inteiro . . . .	11
2.7	<i>DRASiW</i> com processo de <i>Bleaching</i> . . . . .	12
2.8	Janela de Aprendizado da AUTO-WiSARD [11]. . . . .	14
2.9	O Neocognitron . . . . .	16
2.10	Extração de características em uma rede neural <i>Neocognitron</i> . . . . .	18
3.1	Estágio 0 da hierarquia de camadas da NC-WiSARD . . . . .	20
3.2	Estágio 1 da hierarquia de camadas da NC-WiSARD . . . . .	21
3.3	Estágio 2 da hierarquia de camadas da NC-WiSARD . . . . .	22
3.4	Estágio final da hierarquia de camadas da NC-WiSARD . . . . .	23
3.5	Exemplo de extração e concatenação de características na NC-WiSARD	23
3.6	DRASiW dos discriminadores pré-treinados da camada $U_{D_1}$ . . . . .	24

3.7	Possíveis respostas de um discriminador para um determinado conjunto de <i>pixels</i> de entrada. . . . .	25
3.8	Criação dos planos das camadas $U_{S_1}$ e $U_{C_1}$ do estágio $U_1$ . . . . .	26
3.9	Planos $U_{S_1}$ e $U_{C_1}$ sendo formados pelo padrão de entrada em $U_0$ . . . .	27
3.10	Áreas de conexão um plano $U_S$ para formação do plano em $U_C$ . . . .	28
3.11	Áreas de conexão de todos os planos em $U_C$ para a formação de um plano em $U_S$ . . . . .	28
3.12	Treinamento dos discriminadores do estágio 2 através dos quadrantes do padrão de entrada. . . . .	29
3.13	Arquitetura completa de uma possível configuração da NC-WiSARD. . . .	31
3.14	Quantidade de estágios relativos aos tamanhos e configurações dos quadrantes. . . . .	33
3.15	Treinamento da camada de discriminadores do estágio $U_2$ . . . . .	36
4.1	Imagens retiradas do banco de dados <i>Mnist</i> [23]. . . . .	38
4.2	Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 0. . . . .	40
4.3	Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 1. . . . .	41
4.4	Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 0. . . . .	44

# Lista de Tabelas

4.1	Respostas da NC-WiSARD para o teste de sanidade . . . . .	42
4.2	Respostas da NC-WiSARD para padrões diferenciados durante as fases de treinamento e reconhecimento . . . . .	42
4.3	Respostas da NC-WiSARD para o treinamento de um conjunto de cem imagens . . . . .	43

# Capítulo 1

## Introdução

A *WiSARD* [1–10] é uma rede neural que modifica o conteúdo de memórias RAM distribuídas como mecanismo de aprendizado, ao invés de alterações de valores dos pesos. Um conjunto dessas memórias operam como um conjunto de perceptrons, e são capazes de fornecer alto desempenho para o aprendizado da rede. A *AUTO-WiSARD* [11–13] surgiu em resposta a necessidade de uma rede com capacidade de treinamento sem supervisão, ou seja, onde não seja preciso indicar qual a categoria treinada.

Diferente das duas redes já citadas, o Neocognitron é uma rede neural com peso proposta por Fukushima [14–19]. Baseado em estudos feitos sobre o córtex visual humano [20], a arquitetura dessa rede neural simula a hierarquia de camadas de neurônios, possibilitando respostas crescentes em complexidade. Isso significa que nos primeiros níveis da rede são identificados padrões simples como linhas e ângulos, e a medida que a hierarquia evolui, características mais complexas são formadas. Dessa forma é possível treinar e reconhecer padrões de imagens, mesmo que não possuam exatamente as mesmas características, como por exemplo dimensões e posição na imagem.

A NC-WiSARD foi desenvolvida com arquitetura similar a do Neocognitron, mas com o sistema de aprendizado da WiSARD e AUTO-WiSARD. Através do conceito das duas redes sem-peso, é possível extrair a cada nível da hierarquia características importantes de imagens submetidas à rede. Os discriminadores da WiSARD são os

responsáveis pela retenção da informação aprendida e, com a evolução de camadas eles coletam características cada vez mais complexas. Então, ao final da hierarquia, a identificação de imagens é conseguida como na rede neural Neocognitron.

## 1.1 Motivação

Redes neurais artificiais com finalidade de reconhecimento de padrões de imagens, geralmente utilizam imagens que contêm o padrão a ser reconhecido com as dimensões e posicionamento parecidos ao que foi treinado. Outro método muito utilizado, é ajustar a imagem ao padrão para depois alimentar como entrada da rede.

Para resolver esse problema, o Neocognitron utiliza meios similares ao do córtex cerebral humano, reconhecendo padrões completos através da união de características mais simples identificadas anteriormente. Com esse método, a necessidade de ajustes de imagem é descartada, favorecendo a generalidade de entrada.

O Neocognitron é caracterizado como uma rede neural com pesos, por utilizar neurônios baseados em modelos matemáticos. Esse tipo de rede é muito eficaz durante a fase de reconhecimento de padrões, mas durante de etapa de treinamento, muito processamento matemático é exigido afetando o desempenho da rede neural.

Redes neurais que utilizam o sistema de acesso aleatório a memória, como sendo a base de seu neurônio, são denominadas redes neurais sem peso. Por se aproximar mais de um modelo computacional, redes que utilizam esse sistema de neurônios, acabam por ter excelente desempenho tanto na fase de treinamento quanto na de reconhecimento. A WiSARD é um exemplo de rede neural sem peso, e pode-se dizer que o treinamento dessa rede é instantâneo para uma imagem de entrada. Apesar de ser muito eficiente tanto no treinamento e reconhecimento, quanto na taxa de acertos, essa rede não é capaz de identificar padrões que possuam dimensões e posicionamento alterados.

Por essas razões, foi identificada a necessidade da criação de uma nova arquitetura de rede neural, que tirasse proveito dos benefícios de ambas metodologias.

A rede neural artificial sem pesos denominada NC-WiSARD é a resposta a essa necessidade. Baseada na arquitetura de hierarquia de camadas do Neocognitron, e nos neurônios computacionais da WiSARD, a NC-WiSARD utiliza a união de características simples identificadas para o reconhecimento de padrões, podendo estes ser ou não redimensionados e/ou reposicionados.

## 1.2 Objetivo

O objetivo deste trabalho é o desenvolvimento de uma arquitetura de rede neural sem pesos, que seja capaz de reconhecer padrões de dígitos manuscritos. Os padrões apresentados a rede neural na fase de reconhecimento, não precisam ter dimensões e posicionamento similares ao original, para que a rede forneça uma resposta correta. Por meios de configurações realizadas previamente, a rede deve se adequar e ser capaz de receber qualquer tipo de imagem, independente do tamanho ou conteúdo que as caracterize.

## 1.3 Contribuições

Foi proposta uma arquitetura de uma rede neural artificial sem pesos que utiliza o mecanismo de hierarquia multicamadas para extração de características de padrões apresentados na entrada. Essa arquitetura é baseada na rede neural com pesos Neocognitron, que usa a concatenação de características simples para o reconhecimento de padrões complexos.

Uma configuração de arquitetura foi desenvolvida para o reconhecimento de padrões de dígitos manuscritos. Além do desenvolvimento, é mostrada diversas alternativas de configurações para adequar a rede neural para o reconhecimento de quaisquer variações de imagens de entrada.

O potencial da arquitetura é promissor, de forma que estudos futuros possam tornar a rede NC-WiSARD um mecanismo de reconhecimento de padrões genérico e que seja auto-configurável.

## 1.4 Metodologia

Para o desenvolvimento da rede neural sem peso NC-WiSARD foi utilizado a linguagem de programação *Python* [21, 22]. Apesar de não ser a linguagem com melhor desempenho, a escolha se deve ao fato de enfatizar a importância do esforço do programador sobre o esforço computacional. Ou seja, o objetivo final é mostrar resultados corretos, independente da velocidade de processamento.

Para os testes de treinamento e reconhecimento da rede NC-WiSARD, foi utilizado o banco de dados de imagens de dígitos manuscritos *Mnist* [23]. As imagens dessa base de dados, possuem dimensões  $28 \times 28$  *pixels*, e sua coloração é binária, ou seja, apenas *pixels* pretos e brancos compõem os padrões.

## 1.5 Organização da dissertação

O Capítulo 2 introduz os diferentes modelos neurais em que esse trabalho é baseado, assim como é mostrado as principais diferenças e vantagens de cada um. Em seguida, o Capítulo 3, explica o objeto de estudo dessa dissertação, a criação de uma arquitetura de rede neural sem peso denominada NC-WiSARD. Nas seções desse capítulo, será mostrado como foi desenvolvida a arquitetura da rede neural, assim como será explicado como a NC-WiSARD resolve as questões da fase de treinamento e reconhecimento de padrões de imagens. Possíveis configurações da rede neural e decisões tomadas nesse projeto, também são parte integrante desse capítulo. No Capítulo 4, serão mostrados os experimentos que validam a realização desse trabalho, sendo mostrado também resultados da fase de testes. Por fim, o Capítulo 5 conclui o trabalho e apresenta direções para melhorias futuras da NC-WiSARD.



# Capítulo 2

## Modelos Neurais

As primeiras pesquisas na área de redes neurais artificiais surgiram na década de 40, onde o neurofisiologista Warren McCulloch e o matemático Walter Pitts foram os precursores. Eles buscaram desenvolver um modelo matemático de um neurônio a partir de pesquisas do neurônio natural do cérebro humano [20, 24]. Com o passar do tempo, diversos pesquisadores da área buscaram criar, através da união de múltiplos neurônios, redes que fossem capazes aprender e responder à padrões fornecidos como entrada.

Em relação a toda área de redes neurais artificiais, existem hoje duas vertentes possíveis para pesquisas: as redes neurais com pesos e as sem peso. As redes baseadas no neurônio de McCulloch e Pitts utilizam valores numéricos, definidos como pesos, que influenciam na resposta do neurônio. Esses pesos sofrem alterações em seus valores durante o processo de treinamento, que irão influenciar na resposta da rede. Na Figura 2.1, podemos ver o conceito do primeiro neurônio desenvolvido.

Redes neurais sem peso [25, 26] utilizam como menor unidade funcional da rede uma memória de acesso aleatório. É através dos padrões de entrada que são gerados os endereços de armazenamento do conhecimento da rede. A medida que esses valores são alterados, a resposta da rede tende a ser aperfeiçoada. Na próxima seção será abordado de forma mais detalhada o funcionamento das redes neurais sem peso.




Figura 2.1: Neurônio Artificial de McCulloch e Pitts [24]

A WiSARD a AUTO-WiSARD e o Neocognitron são três modelos neurais desenvolvidos para reconhecimento de padrões dentro dessas vertentes. São esses três modelos que formam a base para a criação de uma nova arquitetura de rede neural sem peso, que é a principal contribuição desta dissertação.

## 2.1 Redes Neurais Sem Peso

É através do conceito de endereçamento da memória de acesso aleatório que foi possível o desenvolvimento do neurônio das redes neurais artificiais sem peso. Cada neurônio desta rede consegue endereçar  $n$ -bits, onde  $n$  é a quantidade de bits utilizados dos padrões de entrada. É importante ressaltar que os bits de enderamento das RAMs devem sempre representar a mesma unidade de informação da entrada, por exemplo, se imagens são dadas como entrada, cada RAM sempre observará os mesmos  $n$ -pixels, em suas respectivas posições.

Para o treinamento de uma rede neural sem peso é preciso apenas incrementar o valor do conteúdo de cada RAM, endereçado pelos  $n$ -bits da entrada. Em uma rede sem treinamento, todos os endereços de cada RAM, são inicializadas com valores setados em zero.

Na etapa de reconhecimento, cada neurônio responderá apenas com valores booleanos. Esses valores representam a existência de aprendizado nas posições endereçadas pelos bits de entrada. É possível observar o funcionamento de um neurônio sem peso na Figura 2.2.




Figura 2.2: RAM neurônio  $i$  com  $n$  entradas

Após entender o funcionamento de um neurônio com peso e de um neurônio sem peso, é possível fazer a seguinte analogia: uma RAM responde de forma positiva quando um padrão previamente treinado se repete, enquanto que em um neurônio com peso, sua resposta depende do somatório de influências adquiridas no treinamento. Através dessa analogia é possível concluir que neurônios com pesos reagem a partir das similaridades do aprendizado, provendo assim generalidade na resposta, enquanto que as RAMs respondem apenas de forma booleana.

Na próxima subseção, será mostrado como implementar uma rede neural sem peso que possui capacidade de aprender e reconhecer padrões, mesmo que estes sejam apenas similares aos apresentados durante o treinamento.

### 2.1.1 WiSARD

A WiSARD (**W**ilkie, **S**tonham and **A**leksander's **R**ecognition **D**evice) é uma rede de reconhecimento de padrões, *feedforward* e de uma única camada [1–10]. Esta rede modifica o conteúdo de memórias de acesso aleatório (RAM), com o objetivo de acumular aprendizado. Apesar dos neurônios RAM serem eficientes no

reconhecimento e no apredizado, elas perdem capacidade de generalização, já que reconhecem apenas os padrões apresentados anteriormente. Para superar essa dificuldade, os neurônios são organizados em uma estrutura denominada discriminador (Figura 2.3), em que cada neurônio de um total de  $d$  neurônios é responsável por aprender e reconhecer um subconjunto de um padrão com tamanho  $n \times d$ . O discriminador atua de forma similar aos *perceptrons* definidos por *McCulloch e Pitts*, e cada um tem capacidade completa para reconhecer uma classe de padrões previamente treinada. Desta forma, uma rede neural WiSARD capaz de reconhecer  $n$  classes de padrões, terá em sua arquitetura  $n$  discriminadores.




Figura 2.3: Discriminador

## Treinamento

Para o treinamento de uma rede WiSARD, é modificado o conteúdo das posições das RAMs. Inicialmente o conteúdo das posições de memória é inicializado com zero, pois a rede ainda não possui treinamento. Para indicar qual o endereço da RAM terá seu conteúdo alterado pelo treinamento, randomicamente são escolhidos  $n$  bits do padrão de entrada. O conteúdo que for endereçado pelos  $n$  bits, é incrementado em uma unidade. A escolha randômica das posições dos bits de entrada deve sempre ser a mesma, para todos os discriminadores da WiSARD, assim como para todos padrões de entrada. Dessa forma é garantido a integridade do treinamento na etapa

de reconhecimento.

A WiSARD é uma rede neural que possui característica de treinamento supervisionado, ou seja, é necessário informar a qual classe um determinado padrão pertence. Dessa forma, no momento do treinamento, deve-se informar qual discriminador que representa àquela classe do padrão de entrada.

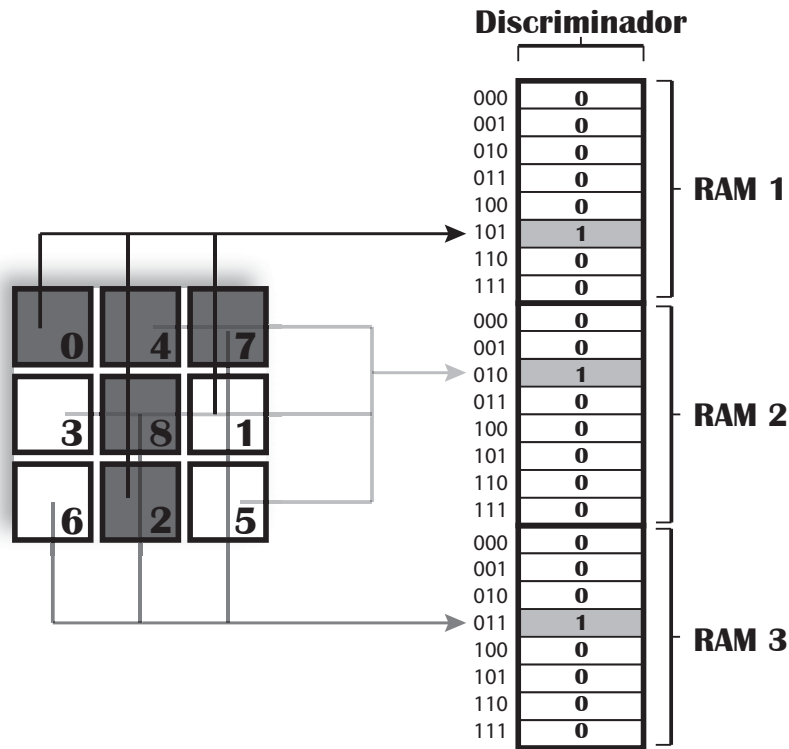


Figura 2.4: Treinamento de um discriminador [6]

Na Figura 2.4, podemos exemplificar o que acontece durante a etapa de treinamento. A escolha randômica dos *pixels* da imagem é representada pela numeração dentro do padrão de entrada  $3 \times 3$ . Seguindo em ordem a numeração dos *pixels*, os endereços de cada RAM são formados, assim como em qual RAM deverá estar treinamento de cada *pixel*. Se somarmos os valores dentro de uma RAM, é possível determinar quantas imagens foram aprendidas por àquele discriminador, que no caso do exemplo foi apenas uma.

## Reconhecimento

A etapa de reconhecimento da rede consiste em analisar as respostas de todos os discriminadores, e escolher àquele que ativou a maior quantidade de neurônios. Um neurônio é ativado quando o subconjunto da entrada, pelo qual o neurônio é responsável, monta um endereço que possua um valor maior do que 0 (zero), em seu conteúdo. O somatório de todas as RAMs de um discriminador é chamado de placar.

Um perceptron WiSARD, na etapa de reconhecimento, é mostrada na Figura 2.5. Neste exemplo, o *discriminador*  $R_1$  ativou maior quantidade de neurônios, chegando ao maior placar. A diferença entre o discriminador com melhor resposta e o segundo melhor é dado por  $d$ , chamado de índice de confiança. Quanto maior  $d$ , maior a chance da rede estar reconhecendo corretamente.

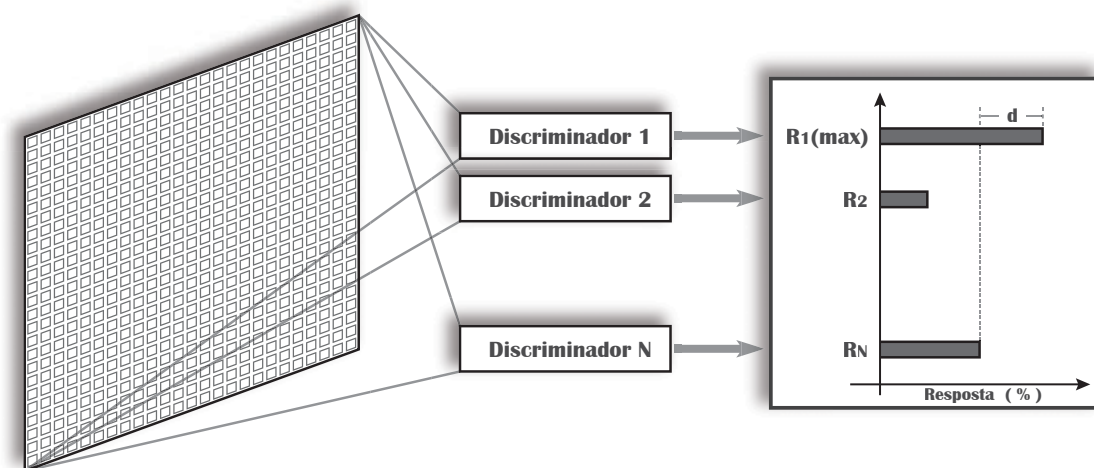


Figura 2.5: A *WiSARD*

## Mecanismo de *Bleaching*

Inicialmente, quando a WiSARD foi projetada, para cada endereço da RAM, existia em seu conteúdo apenas valores de um bit. Essa decisão de projeto foi tomada devido às limitações de hardware da época. Com a arquitetura original, a rede perdia capacidade de reconhecimento se os discriminadores recebessem treinamento em excesso. Quanto mais o conteúdo das RAMs deixavam de ser zeros, mais a imagem

aprendida se tornava turva, chegando até mesmo ser completamente preenchida de *pixels* pretos.

Para corrigir esse problema, uma simples alteração no algoritmo da rede, permite que se obtenha maiores detalhes sobre a etapa de treinamento. Utilizar valores inteiros ao invés de utilizar apenas um bit como conteúdo dos endereços nas RAMs, como mostrado nesta seção. Dessa forma, fica possível saber quais subconjuntos são mais treinados que outros, dentro de um discriminador.

Na Figura 2.6 é possível observar como fica a informação aprendida por um mesmo discriminador tanto no formato binário, quanto com valores inteiros. Com esta modificação, fica agora intuitivo entender o valor de *bleaching* para a etapa de reconhecimento.

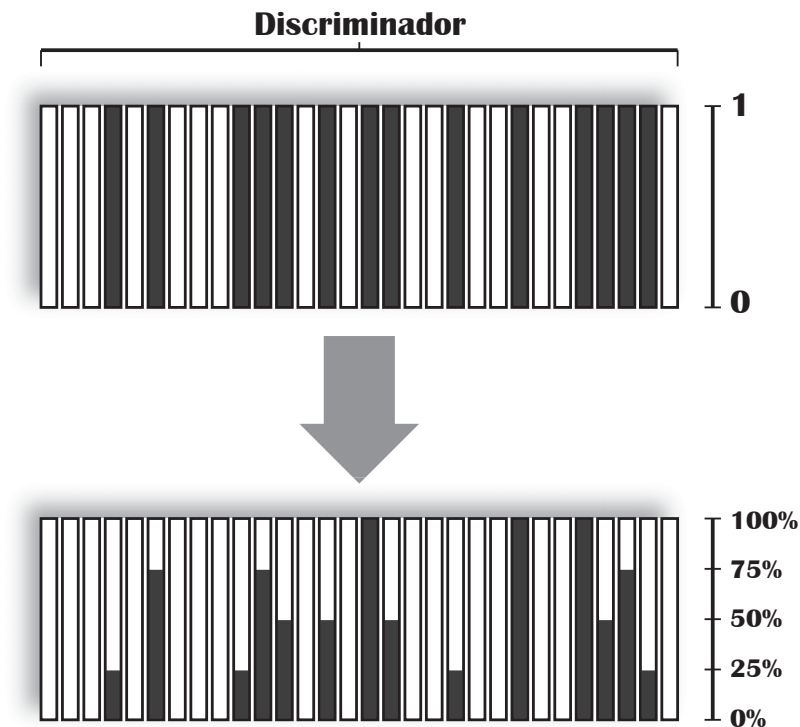


Figura 2.6: Aprendizado de um discriminador em formato binário e inteiro

A medida que a WiSARD é saturada pelo excesso de treinamento, a capacidade de resposta da rede se torna ineficiente. Isso acontece porque os placares das respostas dos discriminadores passam a ser máximos, provocando alguns empates. Utilizando o mecanismo de *bleaching*, torna-se possível desempatar os discriminadores, prevalecendo àquele que representa a classe correta.

Existem duas formas diferentes de *bleaching*: o homogêneo e o heterogêneo. Quando o mesmo valor de *bleaching* é usado para todos os discriminadores, o mecanismo é definido como homogêneo. Se o valor varia de acordo com a quantidade de aprendizado de cada discriminador, o *bleaching* é heterogêneo. Para a escolha de qual mecanismo utilizar, é necessário a realização de testes, pois ainda não existe uma forma de escolher automaticamente.

## DRASiW

Para visualizar o aprendizado do *perceptron* WiSARD, é necessário inverter o processo da etapa de treinamento. Basta varrer as posições de memória de cada neurônio, analisando valores contidos nos endereços das RAMs e decodificando esses endereços para as posições na imagem. Esse processo de recuperação e montagem de padrões aprendidos é chamado de DRASiW.

Por exemplo, se existe um endereço de uma RAM com valor maior que o valor determinado pelo *bleaching*, este endereço contém um treinamento válido a ser decodificado. Se o endereço é 1100, apontado para a primeira RAM de um discriminador, os dois primeiros *pixels* do mapeamento aleatório da imagem gerada serão pintados de preto e os dois seguintes de branco. Na Figura 2.7 é mostrado um exemplo de DRASiW com diferentes valores percentuais de *bleaching*. A primeira imagem representa o *bleaching* desativado e a terceira imagem o valor ótimo de *bleaching*.




Figura 2.7: *DRASiW* com processo de *Bleaching*

## Configuração da rede neural WiSARD

A quantidade de neurônios que formam os discriminadores está diretamente relacionado à quantidade de bits que formam os índices das RAMs. Quanto mais bits



por endereço, menos neurônios irão compor os discriminadores. Podemos analisar da seguinte forma a relação entre esses valores: (i) utilizando apenas um bit de endereçamento, a quantidade de neurônios por discriminador será igual a quantidade de *pixels* do padrão de entrada, generalizando em excesso reconhecimento de diferentes padrões; (ii) utilizando a quantidade total de *pixels* para formar o endereço, o discriminador terá apenas um neurônio, impedindo que seja possível reconhecer padrões diferentes daqueles apresentados à rede na fase de treinamento.

Logo, é importante definir corretamente a quantidade de bits de endereçamento dos neurônios, para existir equilíbrio entre generalidade e especificidade na etapa de reconhecimento. Esse valor irá depender do tamanho do padrão de entrada, da relação entre *pixels* pretos e branco e da quantidade de classes que serão treinadas. Assim como o *bleaching*, não existe um meio de configurar automaticamente a rede. É necessário realizar testes retroalimentados, para que as configurações sejam ajustadas.

### 2.1.2 AUTO-WiSARD

Para que o discriminador correto seja treinado na rede neural sem peso WiSARD, é necessário ter conhecimento a qual classe o padrão de entrada pertence. Com o objetivo de superar esse obstáculo foi proposta então, uma rede baseada em RAMs e discriminadores chamada AUTO-WiSARD [11–13].

A princípio, essa rede é uma WiSARD convencional que escolhe automaticamente qual o discriminador que será treinado, por meio do reconhecimento prévio do padrão de entrada. O discriminador que ativar a maior quantidade de neurônios, será àquele que receberá o treinamento. Apesar de ser uma boa estratégia, se a rede for implementada literalmente desse modo, ela sofrerá com o problema de saturação dos discriminadores e não atingirá estabilidade.

Para resolver esse problema, a AUTO-WiSARD utiliza os seguintes conceitos: aprendizado parcial, janela de aprendizado e alocação semi-probabilística de classes em discriminadores. É através desses conceitos que a AUTO-WiSARD consegue atingir estabilidade no aprendizado, sem que os discriminadores se tornem saturados.

A alocação de novas classes no processo de treinamento, segue as políticas definidas pela janela de aprendizado (Figura 2.8). A janela opera através de limites impostos a quantidade de neurônios que respondem ao padrão de entrada. O limite máximo que um discriminador pode fornecer como resposta é definido por  $r_{max}$ , e a resposta real do discriminador é definido por  $r_{best}$ . Os valores  $r_{max}$  e  $r_{best}$  representam a maior resposta possível do discriminador e resposta real do discriminador, respectivamente. A janela de aprendizado está situada entre os limites  $w_{min}$  e  $w_{max}$ , que definem o que será feito:

- Se  $0 \leq r_{best} \leq w_{min}$ , será alocado um novo discriminador, e este será treinado com o padrão apresentado.
- Se  $r_{best} \geq w_{max}$ , nada será feito, pois a janela admite isso como sendo um padrão muito similar ao que a rede neural já aprendeu.
- Se  $w_{min} \leq r_{best} \leq w_{max}$ , a janela irá decidir probabilisticamente se o discriminador em questão será retreinado, ou se um novo discriminador será criado. A probabilidade do retreino é diretamente proporcional à proximidade do  $r_{best}$  em relação ao  $w_{max}$ .




Figura 2.8: Janela de Aprendizado da AUTO-WiSARD [11].

O objetivo da janela de aprendizado é não deixar que padrões sejam treinados em discriminadores não correspondentes. Se o  $r_{best}$  é menor que  $w_{min}$ , significa que poucos neurônios foram ativados mesmo sendo a resposta com maior placar, e também que o padrão é muito diferente daqueles já aprendidos pela rede neural. Similar a isso, é o que acontece quando o  $r_{best}$  é maior que o  $w_{max}$ , representando uma grande semelhança ao treinamento já realizado. Entretanto, o papel da janela de aprendizado é enfatizado quando a resposta dos neurônios do discriminador atinge valores intermediários. Quando o  $r_{best}$  fica dentro da janela, e se aproxima do  $w_{min}$ , existe pouca semelhança ao que já foi treinado, tornando maior a probabilidade de alocação do padrão a um novo discriminador. O retreino do discriminador é realizado quando o  $r_{best}$  se aproxima do  $w_{max}$ , pois a semelhança é suficiente para afirmar que o padrão está contido na classe, mas não semelhante a ponto de descartar o padrão de entrada.

A característica probabilística da janela de aprendizado, quando o  $r_{best}$  intermedia o  $w_{min}$  e o  $w_{max}$ , foi criada para permitir que padrões tenham a chance de ser alocados em seu próprio discriminador. Dessa forma, ele não irá contribuir com a classe que melhor o representou até o momento. O interessante desse método, é que mesmo se o padrão pertencer a mesma classe que ao discriminador rejeitado, a resposta da rede não será afetada. Isso acontece porque é permitido que uma classe seja representada por um ou mais discriminadores. Por acontecer apenas entre o intervalo definido pela janela de aprendizado, o método é chamado semi-probabilístico.

O aprendizado parcial do conjunto de imagens utilizado no treinamento, evita que os discriminadores sejam saturados. Como visto na seção 2.1.1, discriminadores saturados levam a empates nos placares, prejudicando o funcionamento da etapa de reconhecimento.

Com a união das políticas da janela de aprendizado, o aprendizado parcial e a criação semi-probabilística de discriminadores, é possível tornar a AUTO-WiSARD uma rede neural sem peso estável em apenas de um estágio de treinamento. Isso significa que com um único treinamento de um conjunto de imagens, é garantido que a rede tenha boa taxa de reconhecimento.

## 2.2 Neocognitron

O córtex visual tem a capacidade de identificação de imagens a partir do reconhecimento de conjuntos de padrões simples. Através de camadas de neurônios, os padrões simples são concatenados de uma camada para a outra até formar imagens completas para o processamento cerebral.

O Neocognitron é definido por Fukushima como uma rede neural com peso hierárquica de múltiplas camadas do tipo *feedforward* [14–16, 18]. A rede possui conexões variadas entre células e pode adquirir a habilidade de reconhecer padrões por aprendizado. A arquitetura da rede neural pode ser vista na Figura 2.9.




Figura 2.9: O Neocognitron

Inicialmente a rede de Fukushima foi desenvolvida para o reconhecimento de padrões de números e letras manuscritos, mas ela pode ser adaptada para reconhecer quaisquer conjuntos de padrões. Depois de realizado um processo de treinamento, a resposta das células do estágio mais evoluído da rede, mostra o resultado final do reconhecimento: apenas uma célula responde, e é a célula correspondente à categoria do padrão de entrada. O reconhecimento é feito com base no grau de similaridade, e é eficiente mesmo na presença de deformações, mudanças de tamanho, ou alterações de posição nos padrões de entrada.

O estágio inicial da rede  $U_0$  é composto de uma matriz bi-dimencional de células

receptoras  $u_0$ , correspondendo à imagem a ser reconhecida. Exceto as células  $u_0$ , existem mais dois tipos:

**Células  $S$**  que reconhecem a presença de determinadas característica aprendidas pela rede, em uma determinada posição do padrão de entrada. É importante ressaltar que as características são determinadas durante o treinamento, exceto no estágio 1, onde estas são pré-definidas.

**Células  $C$**  de generalização (ou borramento) para o reconhecimento de padrões com deformações. A presença de camadas de células  $C$  (Figura 2.9) em cada estágio da rede tem um papel importante na habilidade da mesma em reconhecer padrões deslocados. A tolerância para diferenças de posição para características locais (em estágios inferiores), faz com que a mesma célula  $C$  seja ativada no estágio mais alto.

A quantidade de células que compõe o Neocognitron é numerosa, assim como a quantidade de conexões entre elas. Cada conexão representa filtragem de informação, que é feita através dos *pesos* da rede. Os pesos que são ajustados durante o treinamento são àqueles que ligam um estágio ao outro, todos os outros são fixados durante a configuração inicial da rede neural.

Na Figura 2.9 é possível observar que cada camada  $U_S$  e  $U_C$  é composta de planos. É em cada plano que as células  $S$  e  $C$  estão organizadas em matrizes bi-dimensionais. Cada camada  $S$  e  $C$ , nessa ordem, formam o que é chamado estágio. Em cada plano  $S$ , todas as células representam a mesma característica extraída, que somados aos demais planos da camada contemplam características de todo o padrão da entrada. Cada plano  $C$ , do mesmo estágio de  $S$ , é responsável por expandir a capacidade da rede de reconhecer a mesma informação do plano  $S$  ligado a ele. De forma estrutural, todos os estágios têm a mesma funcionalidade, mas cada um trabalha com características mais evoluídas que a do estágio anterior e menos evoluídas que a do posterior.

De forma geral, nos estágios inferiores da rede, características locais, como segmentos de linhas em determinadas orientações, são extraídas, enquanto que nos estágios superiores, as características se tornam completas, representando parte de um padrão ou até mesmo o padrão em sua forma completa (último estágio). A Figura 2.10, mostra como funciona a extração evolutiva de característica em uma rede neural Neocognitron.




Figura 2.10: Extração de características em uma rede neural *Neocognitron*

Desde sua criação, antes chamado apenas de *Cognitron* [19], a rede neural artificial de Fukushima tem sofrido diversas modificações. Por sua eficiência em reconhecimento de padrões de letras e números manuscritos, o Neocognitron foi amplamente comercializado em dispositivos de mão com interface de toque na tela. Várias melhorias já foram propostas ao Neocognitron, como por exemplo a adição de conexões revertidas entre os estágios, na qual traz a capacidade de reconhecimento de múltiplos padrões condensados em apenas uma imagem de entrada [17].

# Capítulo 3

## NC-WiSARD

A partir da arquitetura da rede neural Neocognitron, surgiu a motivação para criar uma rede neural sem peso multicamadas, denominada NC-WiSARD. A utilização da hierarquia de camadas, visa a possibilidade de reconhecimento de padrões mesmo que estes sejam de tamanhos diferentes, ou localizados em uma área diferente do padrão de entrada. Ou seja, com o mesmo conjunto de treinamento utilizado em uma WiSARD, a rede neural será capaz de reconhecer padrões com distorções antes não possíveis.

Nas seções desse capítulo será mostrado a proposta de arquitetura da NC-WiSARD, o funcionamento das etapas de treinamento e reconhecimento, as configurações possíveis que a rede oferece e por fim as decisões de projeto que levaram a arquitetura atual.

### 3.1 Arquitetura proposta

Para entender todo o funcionamento da NC-WiSARD, inicialmente é preciso entender como estão estruturados os estágio da hierarquia de camadas, e qual a funcionalidade de cada elemento da arquitetura.

O primeiro estágio definido como  $U_0$  (Figura 3.1), contempla apenas o padrão de entrada no formato de uma matriz bidimensional, ou seja, é neste momento que é inserida a imagem que a rede neural deve aprender ou reconhecer. É na passagem desse estágio para o próximo, definido como  $U_0 \rightarrow U_1$ , que ocorre a primeira fase de extração de características. Dentro de cada discriminador de  $U_1$ , existe um padrão pré-treinado, que identificará ou não a presença da característica por toda imagem em  $U_0$ .




Figura 3.1: Estágio 0 da hierarquia de camadas da NC-WiSARD

A semelhança entre a etapa de reconhecimento da WiSARD (Seção 2.1.1) e a etapa  $U_0 \rightarrow U_1$ , é proposital. Na WiSARD, os discriminadores representam um padrão por completo, ou seja, todos os *pixels* da imagem são representados em apenas um discriminador. Já na etapa  $U_0 \rightarrow U_1$  da NC-WiSARD, os discriminadores devem representar pequenas características que fazem parte de todas as possíveis entradas da rede.

O estágio  $U_1$ , assim como todos os demais estágios seguintes, é subdividido em três camadas, como mostrado na Figura 3.2. A camada  $U_{D_1}$ , composta de discriminadores, será responsável pela conexão com o estágio anterior. É através dessa conexão que será possível montar os planos contidos na camada  $U_{S_1}$ . Cada célula dos planos da camada  $U_{C_1}$ , é influenciada por um subconjunto de células de apenas



um plano em  $U_{S_1}$ . Com isso, pode-se concluir que a quantidade planos em  $U_{S_1}$  e  $U_{C_1}$ , será a igual ao número de discriminadores em  $U_{D_1}$ . Veremos que apesar da semelhança dos estágios mais avançados da hierarquia, essa regra será válida apenas para  $U_1$ .




Figura 3.2: Estágio 1 da hierarquia de camadas da NC-WiSARD

A partir de  $U_1$ , as conexões entres estágios se tornam mais complexas. Isso ocorre porque depois de separadas todas as características no processo  $U_0 \rightarrow U_1$ , é necessário concatena-las, com o objetivo de criar características mais representativas.

A Figura 3.3 representa o processo  $U_1 \rightarrow U_2$ , e esse processo se repete entre todos estágio superiores na hierarquia, exceto no último. Cada plano de  $U_{S_2}$ , é influenciado por todos os planos do estágio anterior. Cada célula de cada plano dessa camada é resultado do somatório da saída de  $n$  discriminadores. Cada um dos  $n$  discriminadores é treinado por um único plano de  $U_{C_1}$  de um total de  $n$  planos. Cada conjunto de  $n$  discriminadores na camada  $U_{D_2}$ , influencia apenas um plano em

$U_{S_2}$ . Igualmente ao estágio  $U_1$ , as conexões são realizadas entre as células dos planos da camada  $U_{C_2}$  e os planos de  $U_{S_2}$ . A relação entre a camada  $U_S$  e  $U_C$  é similar em todos os estágios superiores, variando apenas a quantidade de células contida nos subconjuntos de  $U_S$ <sup>1</sup>. A quantidade de planos em  $U_{S_2}$  é definida por  $m$ , que também representa a quantidade de conjuntos de  $n$  discriminadores em  $U_{D_2}$ .

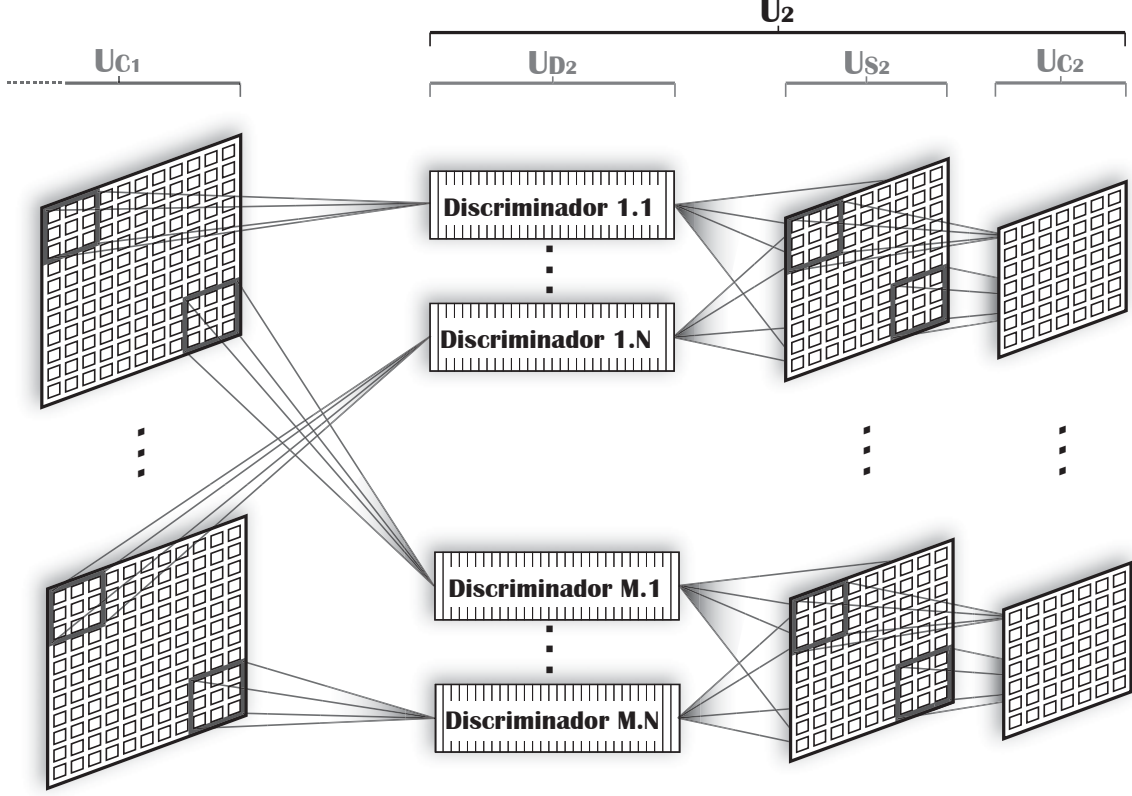


Figura 3.3: Estágio 2 da hierarquia de camadas da NC-WiSARD

Depois que as características concatenadas representam um padrão completo, é necessário treinar o último discriminador. Os discriminadores que contêm o aprendizado do somatório de todas as características de uma classe, formam a última estrutura da hierarquia de camadas (Figura 3.4).

O último estágio definido por  $U_i$  é composto apenas de discriminadores, sendo um para cada classe de padrões treinados. Os planos da camada  $U_C$  no estágio  $U_{(i-1)}$  representam cada um, o somatório de todas as características de uma classe. Cada plano em  $U_{C(i-1)}$  é conectado a todos os discriminadores em  $U_i$ , pois cada discriminador precisa responder a todos os padrões contidos nos planos.

<sup>1</sup>Para todos os planos da mesma camada  $U_S$ , a quantidade de células no subconjunto conectado à  $U_C$ , é sempre o mesmo




Figura 3.4: Estágio final da hierarquia de camadas da NC-WiSARD

## 3.2 Treinamento

A metodologia utilizada para o treinamento da rede é baseada na extração e aprendizado de características relevantes dos padrões de entrada. O processo de extração de características é evolutivo, ou seja, características simples são extraídas nos estágios iniciais, e à medida que se evolui na hierarquia de camadas, elas se concatenam até representar todo o padrão de entrada, como pode ser visto na Figura 3.5.




Figura 3.5: Exemplo de extração e concatenação de características na NC-WiSARD

O treinamento da NC-WiSARD é supervisionado em todos os estágios. Isso significa que as características aprendidas, são separadas por classes de padrões, exceto no primeiro estágio<sup>2</sup>. Em cada estágio da rede existem grupos de discriminadores dedicados a cada classe aprendida, e cada grupo é subdividido em subgrupos que possuem as características de uma determinada área do padrão de entrada. A cada evolução na hierarquia de camadas, as características se unem formando características mais próximas ao padrão de entrada, e por esse motivo acontece uma diminuição na quantidade de subgrupos por classe. Em razão desse processo, no último estágio teremos apenas um discriminador por classe (Figura 3.4).

O conjunto de imagens utilizadas para o treinamento da NC-WiSARD, foi do banco de dados *Mnist* de dígitos manuscritos [23]. As imagens possuem apenas *pixels* pretos e brancos de dimensões  $28 \times 28$ . Para o pré-treinamento<sup>3</sup> da camada de discriminadores do estágio  $U_1$ , foram definidas dimensões de  $3 \times 3$  *pixels* para as características (Figura 3.6). Todos os discriminadores de  $U_{D_1}$  estão presentes nessa figura, sendo representadas todas as possíveis combinações de segmentos de três *pixels*.




Figura 3.6: DRASiW dos discriminadores pré-treinados da camada  $U_{D_1}$ .

Para a realização do treinamento da rede, é preciso treinar todas as camadas de discriminadores  $U_D$ , de forma que a camada  $U_{D_i}$  só possa ser treinada após a camada  $U_{D_{(i-1)}}$ . Com os discriminadores  $U_{D_1}$  prontos, é possível realizar o treinamento do

<sup>2</sup>As características do primeiro estágio são pré-treinadas durante a configuração da rede, e significam apenas segmentos em diferentes ângulos

<sup>3</sup>Discriminadores treinados com conjunto de imagens pré-determinado na fase de configuração da rede.

próximo estágio a partir do conjunto de imagens de entrada gerado nas camadas seguintes de  $U_1$ .

Antes de mostrar como os planos das camadas  $U_S$  são gerados, é preciso entender como cada discriminador responde ao padrão de entrada. Todos os possíveis subconjuntos de  $3 \times 3$  *pixels* da imagem de entrada da rede são utilizados. Podemos observar na Figura 3.7 que o discriminador não só responde ao padrão exato, mas também a determinadas variações. Cada discriminador possui três neurônios sem peso, para isso são utilizados três *pixels* que formam os índices. Sendo três o maior placar possível e zero o menor, o neurônio só responde de forma positiva aos placares dois e três. Se nenhum ou apenas um neurônio ativarem, a característica da imagem de entrada não é considerada, pois problemas poderiam ser causados com a evolução da rede.




Figura 3.7: Possíveis respostas de um discriminador para um determinado conjunto de *pixels* de entrada.

A medida que os discriminadores respondem aos subconjuntos da imagem de entrada, os planos de  $U_{S_1}$  têm seus *pixels* gerados, como pode ser visto na Figura 3.8. Os *pixels* são valores numéricos e proporcionais às respostas dos discriminadores, podendo assumir valores a partir de zero. Os *pixels* são representados com cores em escala de cinzas, sendo branco o *pixel* com valor zero e preto àquele que possui o maior valor em todo o plano.

A camada  $U_{C_1}$  será a responsável pelo treinamento dos discriminadores do próximo estágio. A partir de cada plano em  $U_{S_1}$  é gerado um plano em  $U_{C_1}$  através de um mecanismo de borramento da imagem. É através desse mecanismo que a rede adquire capacidade de conguição de padrões distorcidos em relação aos treinados

originalmente, como por exemplo padrões com tamanhos diferenciados. Isso ocorre porque o mecanismo de borrimento maximiza a área em que o padrão deve estar. A medida que esse borrimento é repetido nos estágios mais evoluídos, um neurônio do último estágio passa a ativar mesmo que a localização da característica não seja mais a original do treinamento.




Figura 3.8: Criação dos planos das camadas  $U_{S1}$  e  $U_{C1}$  do estágio  $U_1$ .

A formação dos planos das camadas  $U_S$  e  $U_C$  em todos os estágios, seguem sempre o mesmo mecanismo. Mas a medida que a rede evolui, os planos dessas camadas passam a ter menor quantidade de *pixels*. Isso ocorre devido ao mapeamento do tamanho das características em relação ao tamanho original. O tamanho da camada  $U_{S_i}$  será sempre reduzido em relação ao tamanho das características aprendidas pela camada  $U_{D_i}$ , e o tamanho dos planos da camada  $U_{C_i}$  reduzidos em relação aos de  $U_{S_i}$ . Se o lado da característica em  $U_{D_i}$  tiver tamanho  $q$  e o padrão de entrada do

estágio anterior lado  $p$ , a imagem formada em  $U_{S_i}$  terá tamanho de lado  $p - q - 1$  (Figura 3.9).




Figura 3.9: Planos  $U_{S_1}$  e  $U_{C_1}$  sendo formados pelo padrão de entrada em  $U_0$ .

O conceito discriminador sinapse surge com o objetivo de explicar a relação entre a área de conexão do padrão de entrada, e a resposta que se torna um *pixel* do plano da camada ou estágio seguinte. Existem as áreas de conexão das células  $S$  e das células  $C$ , localizadas nos planos que as denominam. Apesar de não existirem discriminadores entre as camadas  $U_S$  e  $U_C$ , a Figura 3.10 mostra além das áreas de conexão, como é o funcionamento do mecanismo de borrimento mencionado anteriormente. A área de conexão em um plano em  $U_S$  mapeia apenas um *pixel* no plano relativo em  $U_C$ , e o valor desse mapeamento é o resultado do somatório de todos os *pixels*. Dessa forma, o borrimento consegue aumentar a abrangência da característica que será formada no próximo estágio, em relação à sua posição original na imagem de entrada.

Agora, ao se tratar do mapeamento dos *pixels* em  $U_S$ , além de adicionarmos discriminadores nas sinapses, todos os planos de  $U_C$  influenciarão todas as células de  $U_S$ . Para cada plano em  $U_{S_{i-1}}$ , existe um discriminador sinapse diferente para cada plano em  $U_{C_i}$ , em outras palavras, cada plano em  $U_{C_i}$  receberá o somatório de características aprendidas pelos discriminadores de  $U_{S_{i-1}}$  (Figura 3.11).

Para o treinamento dos discriminadores sinapses, são utilizados quadrantes da imagem de entrada, como mostrado na Figura 3.12. Quanto mais avançado o estágio se encontra na hierarquia da rede, maior o quadrante da imagem se torna.




Figura 3.10: Áreas de conexão um plano  $U_S$  para formação do plano em  $U_C$ .




Figura 3.11: Áreas de conexão de todos os planos em  $U_C$  para a formação de um plano em  $U_S$ .



Cada quadrante é fixo para todos os padrões de entrada, e o conjunto de todos os quadrantes deve representar toda a imagem de entrada. Por ser um treinamento supervisionado, cada quadrante irá sempre treinar o mesmo discriminador do mesmo estágio da NC-WiSARD. O tamanho desse quadrante pode ser variável, mas deverá ser afixado em um mesmo estágio para todas as classes e padrões. Para que a rede funcione corretamente, é necessário que o quadrante aumente suas dimensões ao treinar o próximo estágio, para que no estágio final o quadrante contemple toda a imagem de entrada.




Figura 3.12: Treinamento dos discriminadores do estágio 2 através dos quadrantes do padrão de entrada.

Como explicado na Seção 3.1, todas as camadas  $U_D$  são formadas por diversos discriminadores que estão organizados em conjuntos. Esse conjuntos representam diferentes classes treinadas, e cada discriminador representa um quadrante treinado da classe a que ele pertence.

Após realizar o treinamento de todos os discriminadores de um estágio, é possível treinar os discriminadores do estágio seguinte utilizando os mesmos passos. Após treinar os discriminadores do último estágio, a rede será considerada treinada para

àquele padrão. Para finalizar a etapa de treinamento, basta treinar todos os padrões de todas as classes que foram especificadas no conjunto de treinamento.

### 3.3 Reconhecimento

A NC-WiSARD usa o método de treinamento supervisionado em todos os estágios, logo ela sabe por quais discriminadores cada classe deve passar. Para a etapa de reconhecimento, os caminhos pré-definidos da hierarquia não são utilizados, pois a rede não tem conhecimento prévio de qual classe o padrão de entrada pertence. Na verdade, o objetivo dessa etapa é fornecer ao final, a qual classe àquele padrão de entrada se encaixa.

Nesta etapa, todos discriminadores de todos estágios serão utilizados. Mas apesar de características não pertencentes a classe do padrão de entrada serem utilizadas no processo de concatenação de imagens, discriminadores não pertencentes àquela classe começaram a não responder a medida que se evolui nos estágios da rede. No estágio  $U_1$  todos os discriminadores podem vir a responder positivamente ao padrão de entrada. No estágio  $U_2$  alguns discriminadores começarão ou não a responder, pois começam a existir características não relativas a eles. Seguindo essa ordem, quando estiver no último estágio, um dos seguintes cenários poderá acontecer:

- Apenas ativarão os neurônios de um discriminador, e será este o representante da classe do padrão fornecido como entrada da rede.
- Dois ou mais discriminadores responderão de forma positiva, mas o placar do discriminador representante da classe da imagem de entrada, terá o maior valor.
- Dois ou mais discriminadores responderão de forma positiva, mas ocorreu empate de um ou mais placares. Neste caso é utilizado o método de *bleaching* para o desempate.

Na Figura 3.13 é mostrado um modelo de NC-WiSARD com sua arquitetura completa, além das conexões da etapa de treinamento assim como a de reconhecimento.




Figura 3.13: Arquitetura completa de uma possível configuração da NC-WiSARD.

Através de um conjunto de imagens de treinamento bem selecionado, a NC-WiSARD consegue reconhecer a qual classe um padrão pertence. A etapa de reconhecimento é eficaz não só para imagens pertencentes ao conjunto de treinamento, mas a variações destas também. Existem diferentes tipos de variações, como por exemplo ruídos na imagem, diferenças de tamanho e localização dos padrões, e estas não devem causar interferência em sua capacidade cognitiva.

### 3.4 Configurações

A arquitetura proposta na Seção 3.1, é uma arquitetura base para a desenvolvimento de uma NC-WiSARD. Existem diversas configurações possíveis, e algumas delas podem até mudar a estrutura da rede.

O estágio definido como  $U_0$  é sempre composto pela imagem de entrada, e isso é invariável. Isso não significa que as dimensões da imagem de entrada tenham que

ser fixas. A única restrição que existe no momento, é que o tamanho do conjunto de imagens para treinamento e reconhecimento, tenham que ter as mesmas dimensões. Mas se um outro conjunto de imagens treinar a NC-WiSARD, as dimensões podem ser diferentes.

Em todos os estágios<sup>4</sup> da hierarquia da rede, existe uma camada  $U_D$  composta de discriminadores. Como explicado na Seção 2.1.1, os discriminadores podem conter quantidades variáveis de neurônios. Isso é definido pela quantidade de *pixels* que indexam cada RAM do discriminador. Como cada estágio treina imagens com dimensões diferentes, a quantidade de neurônios dos discriminadores podem variar entre os estágios. Dentro de uma mesma camada  $U_D$ , não podem existir discriminadores com quantidade de neurônios variados, pois isso resultaria em planos com diferentes tamanhos na camada  $U_S$  seguinte.

Definir quantos bits serão usados para indexar o conteúdos dos neurônios, é uma configuração de extrema importância, pois pode resultar em uma rede extremamente eficiente ou extremamente ineficaz. Assim como a quantidade de bits de endereçamento das RAMs, as dimensões das características treinadas nos discriminadores precisam ser cuidadosamente definidas.

As dimensões das características treinadas em cada estágio, também definem como será a hierarquia da rede, ou seja, quantos estágios intermediarão o primeiro e o último. São os quadrantes, explicados na Seção 3.2, os grandes responsáveis pelas dimensões das imagens que irão treinar os discriminadores em cada estágio. O tamanho da imagem de entrada e a quantidade de informação contida nela, são dados importantes que ajudam determinar quanto um quadrante deve representar da imagem de entrada. Na Figura 3.14 é mostrada diferentes configurações de quadrantes que podem influenciar na hierarquia da rede.

O processo de borramento, explicado na Seção 3.2, que acontece entre as camadas  $U_S$  e  $U_C$  de todos os estágios, também é configurável. Dependendo do tamanho das áreas de conexão nos planos em  $U_{S_i}$ , as dimensões dos planos de  $U_{C_i}$  poderão variar. Mais uma vez, quanto maior a área de conexão menores são os planos, e vice-versa. Para cada estágio da NC-WiSARD o tamanho dessas áreas de conexões

---

<sup>4</sup>Exceto o estágio  $U_0$  que é composto apenas pela imagem de entrada.

devem ser constantes, mas para diferentes estgios existe a possibilidade de variao desses valores. Essa configurao tambm pode trazer prejuzos se configurada incorretamente, logo devem ser estudados quais os melhores valores para o processo de borramento<sup>5</sup>.




Figura 3.14: Quantidade de estgios relativos aos tamanhos e configuraes dos quadrantes.

As caractersticas do estgio  $U_1$  foram pr-definidas, mas pode ser utilizado tambm o mtodo de treinamento sem superviso que AUTO-WiSARD oferece (Seo 2.1.2). Estabelecida as dimenses das caractersticas base, que iro alocar os discriminadores de  $U_{D_1}$ , cada discriminador deve ter sua janela de aprendizado configurada. Dependendo dessa configurao a quantidade de discriminadores criados nesse estgio<sup>6</sup>, pode tornar a hierarquia da rede invivel. Para corrigir esse problema,

<sup>5</sup>Quanto maior a rea de conexo para borramento, mais genrica pode se tornar a resposta da rede, podendo tornar ineficaz as respostas da rede neural

<sup>6</sup> muito provvel que discriminadores so criados em excesso.

pode ser necessário eliminar alguns discriminadores considerados muito genéricos, através de um processo de filtragem de características. Esse problema pode ser compreendido melhor com um exemplo: se um discriminador aprendeu características com apenas um *pixel* preto, esse discriminador provavelmente responderá de forma positiva para todas as áreas de conexão. Logo, é uma boa política no processo de filtragem, eliminar discriminadores que contenham características com baixa e alta porcentagem de *pixels* pretos. As características que equilibram *pixels* pretos e brancos, conseguem responder de forma a tornar a rede a mais eficiente possível.

O mecanismo de *bleaching* é utilizado no último estágio para desempatar os placares dos discriminadores, favorecendo àquele que represente a classe correta do padrão de entrada. Utilizando as propriedades desse mecanismo, é possível também eliminar a influência de neurônios<sup>7</sup> ativados incorretamente, na etapa de reconhecimento, entre os estágio intermediários da rede. Como não existe placares incorretos entres os discriminadores sinapses dos estágios, o *bleaching* deve possuir um limite de atuação, ou seja, o quanto de informação deverá "limpar" dos discriminadores. Para encontrar esse limite para cada estágio, deve-se observar as informações dos planos em  $U_S$  do mesmo estágio. Alguns planos devem possuir células com valores maiores que 0 que outros, pois são os planos que representam a classe do padrão de entrada. O mecanismo de *bleaching* deve então favorecer esse cenário.

Alterando todas as possíveis variáveis mostradas nessa seção, a NC-WiSARD pode ser completamente configurada para se adequar a diferentes conjuntos de imagens de entrada. Para o melhor funcionamento possível da rede neural, devem ser feitos testes de validação de reconhecimento de imagens.

### 3.5 Decisões de projeto

Para o banco de dados de imagens<sup>8</sup> escolhido para testes da NC-WiSARD, foi preciso definir como seria a arquitetura e quais seriam as configurações utilizadas. As dimensões das imagens escolhidas eram de  $28 \times 28$  *pixels*. São imagens de caracteres

---

<sup>7</sup>Discriminadores que contenham características não relativas à classe do padrão.

<sup>8</sup>Banco de dados *Mnist* mencionado na Seção 3.2.

númericos de zero a nove, sendo que o conjunto de imagens para treinamento são diferentes das imagens do conjunto para testes de reconhecimento.

Devido às dimensões das imagens de entrada, as características a serem treinadas nos discriminadores do primeiro estágio foram definidas com dimensões de  $3 \times 3$ . As características representam todos os ângulos possíveis de segmentos de retas de três *pixels*, como mostrado na Figura 3.1 na Seção 3.2. Essas imagens formaram o melhor conjunto de características a serem extraídas do conjunto de padrões de entrada escolhido. Testes foram realizados com treinamento não supervisionado para o estágio  $U_1$ , e como foram gerados discriminadores em quantidade elevada, alguns tiveram que ser eliminados para viabilizar a rede. Depois de eliminados todos àqueles que eram muito genéricos, o conjunto restante apresentou-se muito similar ao utilizado no momento. Realizados então testes finais, o conjunto de discriminadores utilizados no momento, apresentou melhores resultados.

Os discriminadores do estágio  $U_1$  por representarem imagens compostas de nove *pixels* no total, a quantidade de RAMs por discriminador ficou sendo três. Se cada RAM fosse indexada por dois *pixels* teríamos seis neurônios, mas assim a resposta de cada discriminador ficaria muito genérica. Acima do valor escolhido, qualquer outro estaria descartando *pixels* de uma imagem já muito reduzida, prejudicando a evolução da rede.

Para cada célula contida nas camadas  $U_C$  de todos os estágios, existe uma área de conexão relativa à camada  $U_S$  do mesmo estágio. Essa área de conexão determina quantas células do plano em  $U_S$  serão utilizadas para ativar o mecanismo de borramento. Quanto maior essa área de conexão, menor será a dimensão dos planos criados em  $U_C$ . Como esses planos são os padrões de entrada para o treinamento dos discriminadores do estágio seguinte, é importante que a informação contida neles não esteja excessivamente turva. A configuração de tamanho da área de conexão para borramento que mostrou melhor resultado, foi de  $3 \times 3$  *pixels* para todos os estágios da NC-WiSARD. Essa configuração foi capaz de fornecer boa generalização para a rede, enquanto que a taxa de acertos na fase de reconhecimento não foi prejudicada.

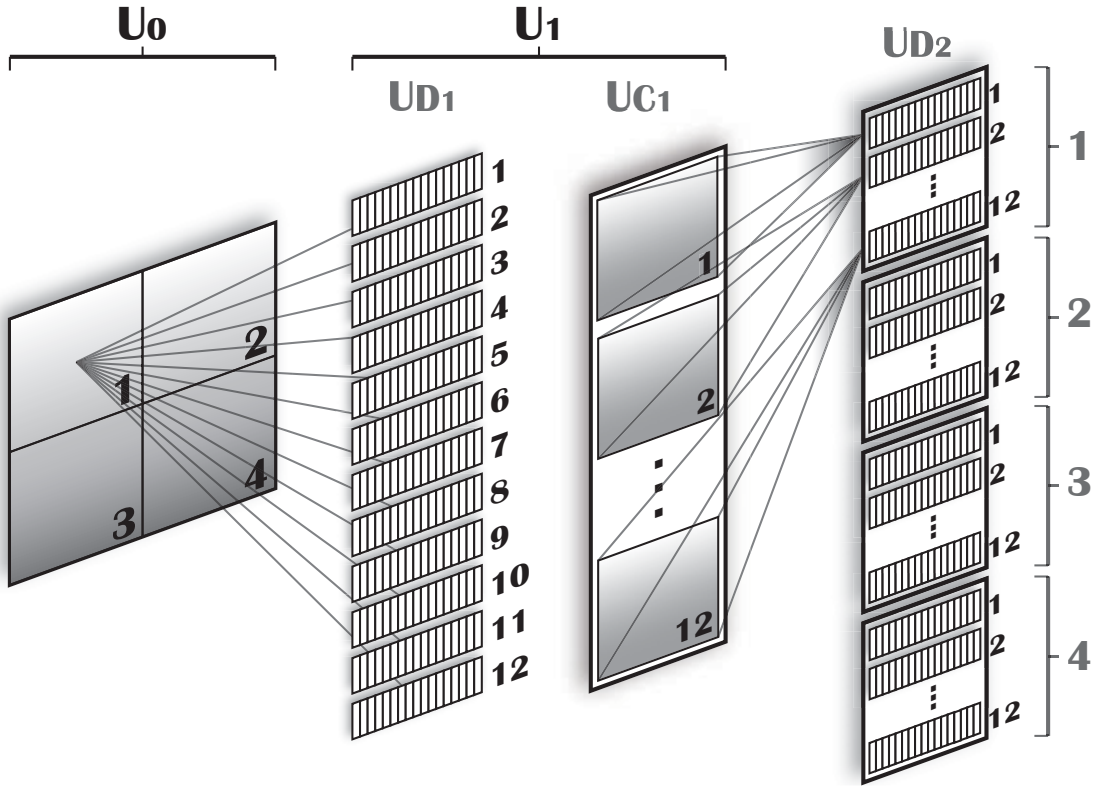


Figura 3.15: Treinamento da camada de discriminadores do estágio  $U_2$ .

Como foram definidos doze discriminadores no estágio  $U_1$ , então o conjunto de treinamento de  $U_2$  será formado por doze planos que compõe  $U_{C_1}$ . Como todos os planos em  $U_{C_1}$  devem influenciar todos os planos em  $U_{S_2}$ , teremos então doze discriminadores para cada plano dessa camada. Cada conjunto de discriminadores deverá representar um de um total de quatro quadrantes do padrão de entrada, como mostra a Figura 3.15. Como para cada classe treinada teremos quatro conjuntos de doze discriminadores, o total de discriminadores em  $U_{D_2}$  para representar as dez classes<sup>9</sup> treinadas, é de 480.

A dimensão de um quadrante em  $U_0$  para o treinamento de  $U_{D_2}$  é de  $14 \times 14$  *pixels*, mas ao chegar em  $U_{C_1}$ , cada plano gerado é reduzido para  $10 \times 10$  *pixels*. A partir das dimensões dos planos de entrada para treinamento de  $U_{D_2}$ , a quantidade de 20 neurônios por discriminador teve melhores resultados dentre o intervalo de 10 à 25 neurônios. Foi observado o comportamento das respostas da rede em diferentes grupos de imagens de treinamento e reconhecimento, e para todos estes, a taxa de acerto da rede sempre foi maior com essa configuração.

<sup>9</sup>Dígitos manuscritos compreendidos entre as classes 0 e 9



A configuração final da rede utiliza quatro estágios na hierarquia, como mostrado na Figura 3.13 da Seção 3.2. Sendo então  $U_3$  o último estágio, os planos em  $U_{C_2}$  formam o conjunto de treinamento de cada um dos dez discriminadores. Os planos de  $U_{C_2}$  são gerados com dimensões  $13 \times 13$  *pixels*, depois de sofrerem reduções de dois processos de borramento, e passarem por duas camadas de discriminadores sinápticos. Para a escolha de quantos neurônios utilizar nos discriminadores do último nível, foram testadas todas as possibilidades entre cinco e quarenta e dois, que indexam trinta e três e quatro *pixels* por RAM, respectivamente. Discriminadores com vinte e um neurônios responderam melhor a todos os testes realizados.

Depois de realizados diversos testes de verificação e validação, a utilização das configurações mostradas nessa seção, explicam o motivo da utilização de quatro estágios na hierarquia da NC-WiSARD, assim como o tamanho das áreas de conexão, tamanho dos quadrantes e quantidade total de neurônios por discriminador.

## Capítulo 4

### Experimentos

Na realização da fase de testes da rede NC-WiSARD, foram utilizadas imagens de dígitos escritos a mão da base de dados *Mnist*. Na Figura 4.1 estão representados dez dígitos para cada classe existente.




Figura 4.1: Imagens retiradas do banco de dados *Mnist* [23].

Essa base de dados é composta de sessenta mil imagens para treinamento e dez mil imagens para teste de reconhecimento. Esses padrões são amplamente usados para a coleta de resultados em redes neurais com finalidades de reconhecimento de imagens, e por isso foram usados para os testes da NC-WiSARD.

Na Seção 4.1, será apresentada a evolução da NC-WiSARD para um conjunto de imagens de entrada, que mostra o real funcionamento da rede implementada. E na Seção 4.2, serão apresentados valores percentuais de taxas de acertos.

## 4.1 Visualizando a NC-WiSARD

Por se tratar de uma arquitetura de rede neural sem peso diferenciada, durante toda a fase de implementação da NC-WiSARD, foram utilizados mecanismos para a visualização do processo de aprendizagem e reconhecimento.

Utilizando o DRASiW, é possível gerar uma imagem representativa a partir das informações internas a um discriminador. Com esse processo é possível enxergar que tipo de padrão está sendo aprendido, e com isso descobrir possíveis irregularidades. Complementar a DRASiW, a NC-WiSARD gera arquivos de imagens das camadas  $U_S$  e  $U_C$  em todos os estágios. Com isso é possível, de forma humana, visualizar toda a evolução multicamadas da rede neural, como podemos ver nas Figuras 4.2 e 4.3.

Para fins representativos, a NC-WiSARD mostrada nas figuras, foi treinada apenas com dígitos das classes 0 e 1, e apenas são mostrado os discriminadores relativos a cada classe nos estágios  $U_2$  e  $U_3$ . Para cada uma das classes treinadas, foram utilizados 10 padrões de entrada. Para essa configuração, a rede respondeu com 100% de acertos para outros 20 padrões apresentados.




Figura 4.2: Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 0.




Figura 4.3: Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 1.

## 4.2 Resultados

Para a coleta de resultados dessa seção, foram realizadas três diferentes etapas de testes: (i) treinamento e reconhecimento alimentados com o mesmo conjunto de imagens; (ii) treinamento e reconhecimento alimentados com imagens diferentes; (iii) reconhecimento alimentado com as imagens redimensionadas e reposicionadas da fase de treinamento.

Na Tabela 4.1 são mostradas as respostas da rede na fase de teste de sanidade. Nesse teste, as imagens utilizadas para o treinamento são também utilizadas na fase de reconhecimento. Todas as imagens utilizadas para esse teste são do banco de dados *Mnist*, e estão incluídas todas as classes de dígitos (0 à 9).

Número de Imagens	Acertos	Erros	Empates	Taxa de Acerto
10	10	0	0	100%
100	99	0	1	99%
1.000	983	9	8	98%
10.000	9.489	507	4	95%

Tabela 4.1: Respostas da NC-WiSARD para o teste de sanidade

Utilizando a mesma proporção de imagens utilizadas na tabela anterior, a Tabela 4.2 mostra os resultados da NC-WiSARD. Para a coleta destes resultados, o conjunto de imagens utilizado para a fase de reconhecimento, é composto de um grupo diferente de padrões daqueles utilizados no treinamento.

Número de Imagens	Acertos	Erros	Empates	Taxa de Acerto
10	10	0	0	100%
100	95	5	0	95%
1.000	862	123	5	86%
10.000	7.221	2.776	3	72%
70.000 - 10.000	6.947	3.053	0	69%

Tabela 4.2: Respostas da NC-WiSARD para padrões diferenciados durante as fases de treinamento e reconhecimento

A última linha da Tabela 4.2 representa o treinamento de todas as imagens do banco de dados, lembrando que para o treinamento existe a quantidade de 60 mil imagens, enquanto que para o reconhecimento existem 10 mil imagens. Comparando o resultado das duas últimas linhas, é perceptível que o treinamento de mais imagens prejudicou o reconhecimento em 3%.

A partir dessa análise, notou-se a importância da qualidade em relação a quantidade de imagens submetidas na fase de treinamento da NC-WiSARD. Com isso, será apresentado na Tabela 4.3 as respostas para o treinamento de apenas 100 imagens, permanecendo a variação da quantidade de imagens para o conjunto utilizado na fase de reconhecimento.

Número de Imagens	Acertos	Erros	Empates	Taxa de Acerto
100	95	5	0	95%
1.000	912	80	8	91%
10.000	8.336	1.643	21	83%

Tabela 4.3: Respostas da NC-WiSARD para o treinamento de um conjunto de cem imagens

Para a terceira etapa de testes, mencionadas no início da seção, foram utilizados os padrões apresentados na Figura 4.4. Foram treinados apenas os padrões com dimensões maiores, enquanto que àqueles com dimensões menores e deslocadas para o canto inferior esquerdo, fizeram parte da fase de reconhecimento. A NC-WiSARD foi capaz de reconhecer 100% dos padrões pertencentes ao conjunto de reconhecimento.

A importância desse último teste, é mostrar a capacidade da NC-WiSARD em reconhecer padrões, mesmo que estes estejam dimensionados ou diferentemente posicionados, em relação aos originais apresentados na fase de treinamento da rede. Os mesmo padrões foram apresentados da forma idêntica a uma rede WiSARD, sendo que esta rede não foi capaz de reconhecer nenhum dos padrões redimensionados e reposicionados.




Figura 4.4: Evolução da NC-WiSARD para um padrão de entrada pertencente a classe 0.

Apesar da rede WiSARD ainda apresentar melhores resultados para os padrões do banco de dados *Mnist*, a NC-WiSARD mostrou competência em reconhecer padrões que tivessem suas dimensões e posicionamento modificados. Os resultados apresentados na Tabela 4.3 mostram uma nova configuração da NC-WiSARD a ser estudada. Por terem sido coletados em um último momento, esses resultados mostram que a NC-WiSARD tem grande potencial para melhorias, e que os resultados mostrados podem ser considerados apenas preliminares.

A arquitetura de hierarquia multicamadas da rede neural sem peso NC-WiSARD, já possui aceitação da comunidade científica através da publicação de um artigo completo no IX Congresso Brasileiro de Redes Neurais / Inteligência Computacional [27].



## Capítulo 5

# Conclusões e Trabalhos Futuros

Neste trabalho foi apresentado uma arquitetura de uma rede neural sem-peso utilizando a hierarquia multicamadas, a NC-WiSARD. Essa rede foi desenvolvida utilizando as principais características do Neocognitron, da WiSARD e da AUTO-WiSARD.

Por meio da hierarquia multicamadas, a rede neural NC-WiSARD é capaz de identificar simples características de padrões nos estágios iniciais, e através da concatenação destes, a rede adquire capacidade cognitiva para responder a classes complexas. Proveniente da estrutura da arquitetura da rede, não são necessários ajustes das imagens de entrada para que a rede consiga responder corretamente a padrões redimensionados e/ou reposicionados.

Mecanismos como o DRASiW e recuperação das imagens geradas pelos planos das camadas  $U_S$  e  $U_C$  da hierarquia da rede, possibilitaram a visualização dos processos de extração e concatenação de características. Através destes mecanismos, foi possível criar diversas possibilidades de configurações, que adaptam a rede a receber tipos diferenciados de padrões e imagens.

Para a realização de testes, foram utilizadas 70 mil imagens do banco de dados *Mnist*. Essas imagens compreendem as dez classes de dígitos manuscritos, em imagens do tipo monocromática.

Os testes realizados mostraram que a NC-WiSARD previamente treinada, conse-

gue responder com boa taxa de acertos, à padrões desconhecidos. A rede mostrou ser capaz de responder com sucesso, a padrões que tiveram suas dimensões e posição alterados, habilidade esta não presente em redes como a WiSARD e AUTO-WiSARD.

Apesar da rede neural proposta neste trabalho não apresentar melhores resultados quantitativos que a WiSARD, para o banco de dados *Mnist*, alguns resultados coletados após o trabalho ser finalizado, mostraram o grande potencial da rede para melhoramentos futuros.

Diversas possibilidades de configurações foram mostradas no Capítulo 3. Essas configurações alteram as características da hierarquia de camadas, extração de características, mecanismo de borrimento, processo de *bleaching*, dentre outros. Com isso a rede modifica sua estrutura para melhorar suas respostas para variados tipos de padrões de entrada. Como trabalho futuro, deve ser eliminado grande parte do trabalho exigido durante a fase de configuração e ajustes de valores da NC-WiSARD. Com isso, espera-se que a rede se torne genérica o bastante para receber qualquer imagem como entrada, com diferentes tamanhos e configurações, e ainda responder com melhores taxas de acertos.

A NC-WiSARD é baseada na metodologia de treinamento supervisionado, logo existe a necessidade de fornecer também como entrada, a classe na qual a imagem pertence. É possível eliminar essa restrição, admitindo em todos os estágios da arquitetura da rede, a forma não supervisionada da WiSARD, a AUTO-WiSARD. Mas para isso, requisitos como auto-configuração, devem ser completados.

A rede neural artificial proposta neste trabalho, demonstra qualidades promissoras para receber novas oportunidades de pesquisa. Com a utilização de uma nova linguagem de programação e as melhorias mencionadas, melhores resultados e desempenho de processamento serão atingidos.

# Referências Bibliográficas

- [1] ALEKSANDER, I., THOMAS, W. V., BOWDEN, P. A. WiSARD: A Radical Step Forward in Image Recognition , *Sensor Review*, pp. 120–124, Julho 1984.
- [2] SOARES, C. M., SILVA, C. L. F., GREGORIO, M., et al. Uma Implementação em Software do Classificador WISARD . In: *Anais do V Simpósio Brasileiro de Redes Neurais*, v. 2, pp. 225–229, Belo Horizonte, 1998. V Simpósio Brasileiro de Redes Neurais.
- [3] BURATTINI, E., CORAGGIO, P., GREGORIO, M. D., et al. Agent WiSARD in a 3D World . In: *IWINAC (2)*, pp. 272–280, 2005.
- [4] GREGORIO, M. D. The Agent WiSARD Approach to Intelligent Active Video Surveillance Systems . In: *MVA*, pp. 331–334, 2007.
- [5] GREGORIO, M. D. Is That Portal Ghotic? A Hybrid System for Recognising Architectural Portal Shapes . In: *MVA*, pp. 389–392, 1996.
- [6] MASSIMO, E. B., GREGORIO, M. D., TAMBURRINI, G. Generating and Classifying Recall Images by Neurosymbolic Computation . In: *Proceedings of the Second European Conference on Cognitive Modelling*, pp. 1–4, 1998.
- [7] BURATTINI, E., CORAGGIO, P., DE GREGORIO, M. Agent WiSARD: a hybrid system for reconstructing and understanding two-dimensional geometrical figures . In: *Design and application of hybrid intelligent systems*, pp. 887–896, Amsterdam, The Netherlands, The Netherlands, 2003. IOS Press. ISBN: 1-58603-394-8.

- [8] GRIECO, B. P. A., LIMA, P. M. V., GREGORIO, M. D., et al. Producing pattern examples from "mental"images , *Neurocomputing*, v. 73, n. 7-9, pp. 1057–1064, 2010.
- [9] BURATTINI, E., GREGORIO, M. D., TAMBURRINI, G. Mental Imagery in Explanations of Visual Object Classification . In: *SBRN*, pp. 137–143, 2000.
- [10] CORAGGIO, P., GREGORIO, M. D. WiSARD and NSP for Robot Global Localization . In: *IWINAC (2)*, pp. 449–458, 2007.
- [11] WICKERT, I. *Modos de Aprendizado Não-Supervisionado para o Modelo Neural Sem-Pesos WiSARD*. Tese de Mestrado, COPPE/UFRJ, 2001.
- [12] WICKERT, I., FRANÇA, F. M. G. Validating an unsupervised weightless perceptron . In: *Proc. 9th International Conference on Neural Information Processing ICONIP 02*, v. 2, pp. 537–541, November 2002. doi: 10.1109/ICONIP.2002.1198114.
- [13] WICKERT, I., FRANÇA, F. M. G. AUTOWISARD: Unsupervised Modes for the WISARD . In: *Lecture Notes in Computer Science*, v. 2084, pp. 435–441, 2001.
- [14] FUKUSHIMA, K. Neocognitron for handwritten digit recognition , *Neurocomputing*, v. 51, pp. 161–180, 2003.
- [15] FUKUSHIMA, K. Neocognitron: A Hierarchical Neural Network Capable of Visual Pattern Recognition , *Neural Networks*, v. 1, pp. 119–130, 1988.
- [16] FUKUSHIMA, K. A Neural Network for Visual Pattern Recognition , *Computer*, v. 21, n. 3, pp. 65–75, 1988. ISSN: 0018-9162.
- [17] FUKUSHIMA, K. Restoring partly occluded patterns: a neural network model with backward paths . In: *ICANN/ICONIP 03: Proceedings of the 2003 joint international conference on Artificial neural networks and neural information processing*, pp. 393–400, Berlin, Heidelberg, 2003. Springer-Verlag. ISBN: 3-540-40408-2.

- [18] FUKUSHIMA, K. Neocognitron capable of incremental learning , *Neural Netw.*, v. 17, n. 1, pp. 37–46, 2004. ISSN: 0893-6080. doi: [http://dx.doi.org/10.1016/S0893-6080\(03\)00078-9](http://dx.doi.org/10.1016/S0893-6080(03)00078-9).
- [19] FUKUSHIMA, K. Cognitron: A self-organizing multilayered neural network , *Biological Cybernetics*, v. 20, pp. 121–136, 1975.
- [20] HUBEL, D. H., WIESEL, T. N. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex , *Journal de Physiologie*, v. 106, n. 1, pp. 106–154, 1962.
- [21] PYTHON. Python Language Reference . , 2010. Disponível em: <<http://docs.python.org/reference/>>. Último acesso em: setembro.
- [22] PYTHON. Python Image Library - PIL . , 2010. Disponível em: <<http://www.pythonware.com/products/pil/>>. Último acesso em: setembro.
- [23] LECUN, Y., CORTES, C. MNIST handwritten digit database . , 2010. Disponível em: <<http://yann.lecun.com/exdb/mnist/>>. Último acesso em: setembro.
- [24] HOPFIELD, J. J. Neural networks and physical systems with emergent collective computational abilities , "Proc. of the National Academy of Science, USA ", pp. 7–19, 1999.
- [25] ALEKSANDER, I., MORTON, H. *An introduction to neural computing*. New York, NY, USA, Van Nostrand Reinhold Co., 1990. ISBN: 0-442-31218-0.
- [26] AUSTIN, J. *RAM-Based Neural Networks*. River Edge, NJ, USA, World Scientific Publishing Co., Inc., 1998. ISBN: 9810232535.
- [27] BANDEIRA, L. C., FRANÇA, H. L., FRANÇA, F. M. G. NC-WiSARD: Uma Interpretação booleana da Arquitetura Neocognitron . In: *Anais do IX Congresso Brasileiro de Redes Neurais / Inteligência Computacional*, pp. CD–Rom, Ouro Preto, MG, Brasil, 2009.