

UM ESTUDO DE CLASSIFICAÇÃO DE ESPECTROS DE FOURIER USANDO A REDE NEURAL SEM-PESOS AUTOWISARD

Iuri Wickert e Felipe M. G. França

Programa de Engenharia de Sistemas de Computação - COPPE - UFRJ
Cidade Universitária, Centro de Tecnologia, Bloco H - Sala 319
Caixa Postal: 68511 CEP: 21945-970 Rio de Janeiro, RJ, Brasil
Telefone: +55 21 2562-8675 Fax: +55 21 2562-8676
E-mails: iwickert@yahoo.com, felipe@cos.ufrj.br

RESUMO

This paper presents a novel approach to the problem of automatized categorization and classification of Fourier spectrum through the use of the AUTOWISARD weightless neural model. Figures from experimental results, taken into account variations on the weightless neural model adopted, are discussed.

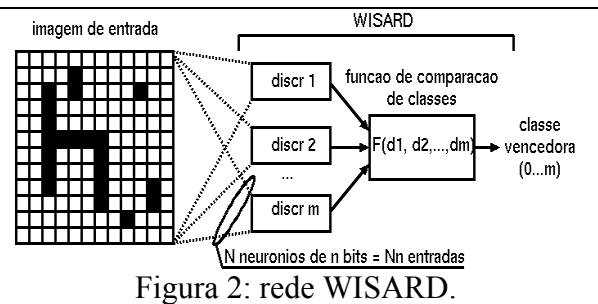

1. INTRODUÇÃO

Neste trabalho apresentamos a rede neural AUTOWISARD [1][2], uma rede sem-pesos, não-supervisionada, de aprendizado rápido e simples implementação, com potencial comprovado como classificadora de padrões complexos e de grande dimensionalidade (ex. dígitos manuscritos) [3]. A proposta deste trabalho é estudar a métodos de representação de espectros adequados à rede AUTOWISARD, bem como verificar a qualidade de classificação desses espectros que pode ser obtida por esta rede. Essas informações são relevantes para ajudar a determinar a viabilidade do uso desta rede como parte de um sistema de aquisição automática de classes de espectros (navios), que apresente robustez e baixo custo computacional.


2. A REDE AUTOWISARD

A rede neural AUTOWISARD ("AW") é uma variante da conhecida rede sem-pesos WISARD [4][5], uma rede neural normalmente usada no domínio das aplicações baseadas em imagens. A AW é capaz de aprender, de modo não-supervisionado, diferentes classes de padrões binários, atingindo um estado estável após uma única época de treinamento.

A rede WISARD é uma rede sem-pesos, isto é, armazena seu conhecimento em elementos endereçáveis de memória (neurônios RAM, neste caso, com palavra de 1 bit), em oposição à redes tradicionais (MLP, Kohonen), que armazenam seu conhecimento em pesos (números reais) conectando seus neurônios. Um neurônio RAM, com n bits de endereçamento, é capaz de aprender e reconhecer 2^n diferentes padrões de n bits, ou tuplas, e é inicializado com zeros. Seu treinamento consiste em escrever '1' na posição endereçada pela tupla; o reconhecimento ou rejeição de uma tupla é determinado pelo conteúdo da posição endereçada pela mesma (1 ou 0). Mesmo sendo capaz de aprender e reconhecer padrões, o neurônio RAM, no entanto, não provê generalização: reconhece apenas padrões idênticos aos previamente treinados. Para superar essa limitação, um conjunto de neurônios pode ser organizado numa estrutura reconhecedora de classes, chamada discriminador (figura 1).



Num discriminador, cada neurônio é responsável pelo aprendizado e reconhecimento de um subconjunto dos bits da entrada original; a atribuição desses subpadrões a seus respectivos neurônios é feito por um mapeamento bits-neurônios fixo, usando tanto na fase de treinamento quanto no reconhecimento de padrões. O treinamento de um discriminador consiste em treinar suas RAMs com seus respectivos subpadrões; já o nível de reconhecimento de uma entrada consiste na soma das saídas das RAMs. A rede WISARD, então, é um vetor de discriminadores, cada um representando uma classe distinta, juntamente com uma função de comparação de classes (figura 2). Essa função geralmente é a função de máximo (retorna o rótulo associado ao discriminador que apresentou a maior saída).



A rede AW é a versão não-supervisionada da WISARD, ou seja, é uma WISARD que pode criar novas classes dinamicamente, assim como determinar o quanto aprender, ao contrário do modelo original, cujo treinamento é supervisionado. Para tanto, ela utiliza um método chamado de janela de aprendizado, que é uma região definida sobre o intervalo de reconhecimento de um discriminador

(figura 3), definida pelos parâmetros w_min e w_max , $0 \leq w_min \leq w_max \leq r_max$, r_max sendo o número de neurônios no discriminador. Desse modo, tendo-se r_best como o maior nível de reconhecimento de uma rede WISARD para uma entrada, se:


- $0 \leq r_best \leq w_min$, um novo discriminador será incorporado à rede, sendo treinado com essa entrada. Assume-se que este padrão não estava representado no estado anterior da rede.
- $w_min < r_best < w_max$, um novo discriminador poderá ser incorporado à rede e treinado, ou então o discriminador vencedor sofrerá um aprendizado parcial. Esse aprendizado consiste em selecionar aleatoriamente $(w_max - r_best)$ neurônios entre os que falharam no reconhecimento, e treiná-los. A ação (criação ou treinamento) será decidida por uma variável aleatória ponderada pela posição de r_best dentro da janela de aprendizado.
- $w_max \leq r_best$, nenhuma ação será executada (estado estável). Assume-se que este padrão já estava adequadamente representado no estado da rede.

A aplicação do algoritmo da janela de aprendizado, juntamente com o aprendizado parcial e a monotonicidade do neurônio RAM, garantem que a AW atinja um estado estável após uma

única época de treinamento, e que qualquer um dos padrões treinados terá um grau mínimo de reconhecimento ($r_best \geq w_max$).

3. CODIFICAÇÃO DE ESPECTROS

Neste trabalho, foram usadas as versões pre-processadas, presentes no cdrom, dos sinais de áudio originais (arquivos sem sufixo), previamente rotulados em 8 classes distintas: A, B, C,



D, E, F, G e H. Para gerar esses arquivos de espectros, os sinais originais sofreram decimação por 2, e foram transformados usando FFT com 2048 pontos, sendo limitados em frequência até 3kHz, equivalente a 557 pontos. Finalmente, os espectros resultantes foram filtrados usando TPSW [6] (figura 4).

Para adequar os espectros para uso com a rede AW, e, ao mesmo tempo, preservar o aspecto visual dos mesmos, uma sequência de outros métodos foram aplicados sobre cada espectro (figura 5):

- Redução da dimensionalidade dos espectros. Cada espectro foi dividido em intervalos de p pontos, gerando um espectro resultante composto pela soma dos pontos de cada um desses intervalos. Neste trabalho, foi adotado $p = 3$.
- Binarização dos espectros. As frequências (índices) dos k maiores picos presentes em cada espectro são representada com o bit 1, as demais com zeros. ($k = 8$).
- "Média" entre espectros vizinhos. Para reduzir a variação das frequências dos picos entre espectros vizinhos, novos espectros foram gerados, fazendo uma operação "ou" lógica (OR) entre os espectros dentro de uma janela móvel com largura v . ($v = 5$)

4. EXPERIMENTOS E RESULTADOS

Os experimentos foram realizados usando-se a rede AW em diferentes configurações de tamanho de tupla e janela de aprendizado. O treinamento de cada rede foi feito apresentando-se todos os espectros, em ordem aleatória e sem considerar o rótulo de cada espectro, a uma nova rede, com um mapeamento bits-entradas distinto. Após o treinamento, foi levantado o perfil de cada classe gerada pela rede, isto é, o número de espectros reconhecidos por rótulo e por classe; assim, cada classe recebeu o rótulo mais frequente dentro do conjunto de espectros reconhecidos pela mesma.

Rede	Tupla	W min	W max	Classes	% dos espectros na maior classe	Rótulos na classe
1	6 bits	50%	70%	96	98,38%	8
2	8 bits	40%	60%	119	99,04%	8
3	4 bits	40%	60%	5	99,96%	8
4	7 bits	35%	60%	113	98,78%	8
5	5 bits	30%	50%	19	99,66%	8

Tabela 1: resultados de 5 execuções da rede AW.

Devido os resultados insatisfatórios obtidos nos experimentos e limitações de espaço, a descrição de cada execução se limitará a apresentar os parâmetros da rede, o número de classes geradas e o perfil da classe que reconheceu o maior percentual de espectros (tabela 1).

5. ANÁLISE DOS RESULTADOS

Observando-se os resultados presentes na tabela 1, percebe-se que, independentemente da quantidade de classes geradas (grau de generalização) ou configuração da rede AW, sempre surgiu uma classe que reconheceu a grande maioria dos espectros, denotando um resultado claramente insatisfatório do ponto de vista de classificação. Esse tipo de situação indica deficiências na codificação e representação binária dos espectros, implicando que os métodos empregados nessa etapa não aumentaram a densidade de informação contida nos espectros originais, mesmo usando-se métodos para redução da dimensionalidade (isto é, melhoria da relação entre números de bits ligados e desligados) desses espectros. A adoção de um número fixo de picos (p) na etapa de binarização, para todos os espectros, pressupõe que todas as classes de navios tenham o mesmo número de componentes espectrais relevantes, assim como propicia o surgimento de falsos padrões, isto é, sinais com intensidade demasiadamente baixa para serem classificados normalmente ainda assim podem ser interpretados como sendo oriundos de navios (ao invés de serem rejeitados).

6. CONCLUSÕES

Neste trabalho foi apresentada a rede neural AUTOWISARD, uma nova rede sem-pesos não-supervisionada rápida, simples e capaz de aprender padrões complexos, tendo como contexto uma aplicação de classificação de espectros de Fourier de ruídos gerados por navios. Apesar dessa rede apresentar as características necessárias para compor um sistema de classificação de padrões automático, seu desempenho nessa tarefa foi prejudicado pela representação escolhida para os espectros, que privilegia a fidelidade ao (aspecto visual dos) espectros originais, às expensas da extração de suas componentes relevantes. O bom desempenho da rede AW na classificação de padrões visuais complexos, no entanto, sugere a necessidade de maiores estudos sobre representações alternativas dos espectros, que possam melhor explorar a capacidade de classificação desta rede neural.

7. REFERÊNCIAS

- 1.I. Wickert and F. M. G. França, "AUTOWISARD: unsupervised modes for the WISARD", Lecture Notes in Computer Science 2084, 435-441 (2001).
- 2.I. Wickert and F. M. G. França, "Validating an unsupervised perceptron", Proceedings of the 9th International Conference on Neural Information Processing, Cingapura (2002).
- 3.I. Wickert, "Modos de aprendizado não-supervisionado para o modelo neural sem-pesos WISARD", Tese de mestrado, COPPE-UFRJ, Rio de Janeiro (2001).
- 4.I. Aleksander, W. Thomas and P. Bowden, "WISARD, a radical step forward in image recognition", Sensor Review 4, 120-124 (1984).
- 5.I. Aleksander and H. Morton, "An introduction to neural computing", Chapman and Hall, London (1991).
- 6.W. Soares-Filho, "Classificação do ruído irradiado por navios usando redes neurais", Tese de doutorado, COPPE-UFRJ, Rio de Janeiro (2001).